

信息论考试笔记

哈工深·人工智能院士班

授课教师：白方（教授）

2026 年 7 月 8 日

核心参考教材：Cover & Thomas, *Elements of Information Theory*, 2nd ed.

目录

1 信息度量	3
1.1 自信息量	3
1.2 熵	3
1.3 条件熵与联合熵	3
1.4 互信息	4
1.5 KL 散度与交叉熵	4
1.6 多元拓展与链式法则	5
1.6.1 条件互信息	5
1.6.2 互信息的链式法则	5
1.6.3 多元条件熵	5
1.6.4 联合熵的链式法则（多元形式）	6
1.6.5 互信息与熵的完整关系图	6
1.6.6 条件 KL 散度	6
2 不等式与凹凸性	6
2.1 Jensen 不等式	6
2.2 Log-sum 不等式	7
2.3 KL 散度非负性（Gibbs 不等式）	7
2.4 重要推论	7
2.5 凹凸性总结	8
3 渐进均分性（AEP）——独立同分布	8
3.1 理论准备	8
3.2 AEP 与典型集	8
3.2.1 典型集的最小性	9
3.2.2 典型集内概率真的“等分”吗？	10
3.2.3 二项分布视角	10
3.3 信源定长编码定理	10
4 Kraft 不等式与变长编码	11
4.1 编码分类与关系	11
4.2 Kraft-McMillan 不等式	11
4.3 最优编码长度	11
4.4 变长码编码定理与编码开销	12
5 Huffman 最优前缀码	12
5.1 Huffman 算法	12

5.2	最优性证明	12
5.3	块编码	12
6	AEP —— 平稳遍历过程	12
6.1	平稳过程	12
6.2	熵率的存在性与等价性	13
6.3	平稳马尔可夫过程	13
6.3.1	状态转移矩阵	13
6.3.2	k 步转移与 Chapman-Kolmogorov 方程	13
6.3.3	稳态分布	14
6.3.4	平稳马尔可夫链的熵率	14
6.3.5	完整计算实例 (4 状态链)	14
6.4	遍历性	15
6.4.1	不可约性 (Irreducibility)	15
6.4.2	非周期性 (Aperiodicity)	15
6.4.3	平稳遍历的层次关系	16
6.5	Shannon-McMillan-Breiman 定理	16
7	数据处理不等式与 Fano 不等式	16
7.1	马尔可夫链	16
7.2	数据处理不等式 (DPI)	16
7.3	充分统计量	17
7.3.1	因子分解定理 (核心基础)	17
7.3.2	从因子分解到条件分布与 θ 无关	17
7.3.3	高斯实例: 走一遍完整推导	18
7.3.4	三种等价表述	18
7.3.5	指数族分布与充分统计量	19
7.3.6	常见指数族分布的充分统计量	19
7.3.7	判断与证明方法总结	19
7.4	Fano 不等式	20
8	噪声信道编码定理与联合典型性	20
8.1	通信系统模型	20
8.2	噪声信道编码定理	21
8.3	联合典型集	21
8.3.1	定义与基本性质	21
8.3.2	联合典型引理 (Joint Typicality Lemma)	21
8.4	正向证明 (若 $R < C$, 则存在编码方案使 $P_e \rightarrow 0$)	22
8.4.1	Step 1: 香农的期望技巧	22
8.4.2	Step 2: 随机码本构造	22

8.4.3	Step 3: 联合典型译码规则	23
8.4.4	Step 4: 误差概率分析 (Union Bound)	23
8.4.5	Step 5: 取极限与存在性	24
8.4.6	正向证明小结	24
8.5	反向证明 (若 $R > C$, 则任何编码方案都有 $P_e > 0$)	24
8.5.1	Step 1: Fano 不等式给出误差下界	24
8.5.2	Step 2: DPI 消除编码器	24
8.5.3	Step 3: 用 DMC 放缩 $I(X^n; Y^n) \leq nC$	25
8.5.4	Step 4: 得出结论	25
8.5.5	小结: 正向 vs 反向的假设差异	25
8.6	几何解释	25
8.7	平均误差到最大误差 (Expurgation)	26
9	信道容量计算	26
9.1	信道容量计算	26
9.1.1	对称信道的判断方法	27
9.1.2	对称信道容量计算	27
9.1.3	对称信道实例 (附容量推导)	27
9.1.4	非对称信道如何处理	28
10	Hamming 码	28
10.1	核心思想: 数据流形	28
10.2	GF(2) 算术与错误表示	29
10.3	汉明矩阵 H 的结构	29
10.4	编码流程 (Hamming(7,4) 实例)	29
10.5	译码流程	30
10.6	Hamming 距离	30
11	连续情况与高斯信道	30
11.1	微分熵	30
11.2	高斯分布——最大熵分布	31
11.3	高斯信道	31
11.4	并行高斯信道——水填充 (Water-Filling)	31
12	率失真理论——有损压缩	32
12.1	问题表述	32
12.2	常用失真函数	32
12.3	率失真函数	32
12.4	率失真函数性质	32
12.5	高斯信源的率失真函数	33

13 率失真与信道编码的假设对比	33
14 信源信道分离	33
14.1 问题背景	33
14.2 分离方案 (Separation Scheme)	33
14.3 联合编码方案 (Joint Coding Scheme)	34
14.4 联合方案的必然约束 (反向证明)	34
14.5 分离定理 (Separation Theorem)	35
15 变分自编码器 (VAE) 与率失真理论	35
15.1 率失真问题的三种形式	35
15.2 VAE 的基本结构	35
15.3 ELBO 的来源	36
15.4 从信息论角度看 VAE	36
15.4.1 正则项 = 编码率 (Rate)	36
15.4.2 重建误差 = 失真度 (Distortion)	36
15.4.3 VAE 就是在逼近率失真极限	36
15.4.4 β -VAE	37
15.5 考试要点	37
16 核心公式速查	37
17 关键证明思路汇总	39

1 信息度量

1.1 自信息量

定义 1.1 (自信息量的公理化推导). $I(x) = f(p(x))$ 需满足:

- (1) $f(p)$ 单调递减——事件概率越小, 信息量越大;
- (2) 独立事件: $f(p_1 p_2) = f(p_1) + f(p_2)$;
- (3) 连续性: $|p_1 - p_2| \rightarrow 0 \Rightarrow |f(p_1) - f(p_2)| \rightarrow 0$ 。

唯一解: $I(x) = k \log p(x)$, 其中 $k < 0$ 。

常用底数对应单位:

- $-\log_2 p(x)$: 比特 (bit)
- $-\ln p(x)$: 奈特 (nat)
- $-\lg p(x)$: 哈特 (hart)

1.2 熵

定义 1.2 (信息熵).

$$H(X) = \mathbb{E}_X \left[\log \frac{1}{p(X)} \right] = \sum_X p(x) \log \frac{1}{p(x)} = H(p)$$

性质 1.3. (1) 熵由分布 p 完全确定, 与 X 具体取值无关;

(2) 非负性: $H(p) \geq 0$;

(3) 顺序无关性: $H(p_1, \dots, p_i, \dots, p_j, \dots, p_q) = H(p_1, \dots, p_j, \dots, p_i, \dots, p_q)$ 。

均匀分布熵最大

$H(p) \leq \log |\mathcal{X}|$, 等号当且仅当 p 为均匀分布。

典型值: 0-1 分布 $H(p) = p \log \frac{1}{p} + (1-p) \log \frac{1}{1-p}$; N 等分均匀分布 $H = \log N$ 。

1.3 条件熵与联合熵

定义 1.4 (条件熵).

$$H(X|Y) = \mathbb{E}_{XY} \left[\log \frac{1}{p(X|Y)} \right] = \sum_Y p(y) H(X|Y=y)$$

充分观测 Y 后 X 剩余的不可预测性。 $H(X|Y) \leq H(X)$ 。

定义 1.5 (联合熵).

$$H(X, Y) = \mathbb{E}_{XY} \left[\log \frac{1}{p(X, Y)} \right]$$

定理 1.6 (链式法则).

$$\begin{aligned} H(X, Y) &= H(X) + H(Y|X) = H(Y) + H(X|Y) \\ H(X, Y|Z) &= H(X|Z) + H(Y|X, Z) \\ H(X_1, \dots, X_N) &= \sum_{i=1}^N H(X_i|X_{i-1}, \dots, X_1) \end{aligned}$$

1.4 互信息

定义 1.7 (互信息).

$$I(X; Y) = \sum_{XY} p(x, y) \log \frac{p(x, y)}{p(x)p(y)} = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

信息增益 = 之前的熵 - 之后的熵 = 不可预测性减少量。

性质 1.8. (1) 对称性: $I(X; Y) = I(Y; X)$;

(2) 非负性: $I(X; Y) \geq 0$, 等号当且仅当 $X \perp\!\!\!\perp Y$;

(3) $I(X; X) = H(X)$;

(4) $I(X; Y) \leq H(X)$, $I(X; Y) \leq H(Y)$;

(5) $I(X; Y) = H(X) + H(Y) - H(X, Y)$ 。

1.5 KL 散度与交叉熵

定义 1.9 (KL 散度).

$$D_{\text{KL}}(p||q) = \sum_X p(x) \log \frac{p(x)}{q(x)}$$

非负性: $D_{\text{KL}}(p||q) \geq 0$ (Gibbs 不等式), 等号当且仅当 $p = q$ 。KL 散度不对称也不满足三角不等式, 不是严格的距离。

互信息与 KL 散度的关系

$$I(X; Y) = D_{\text{KL}}(p(X, Y)||p(X)p(Y)) \geq 0$$

定义 1.10 (交叉熵).

$$\text{CE}(p||q) = H(p) + D_{\text{KL}}(p||q) = \sum_X p(x) \log \frac{1}{q(x)}$$

用 q 近似 p 时的总编码开销。 $\min_q \text{CE}(p||q) \Leftrightarrow \min_q D_{\text{KL}}(p||q)$ 。

Venn 图核心关系

$$\begin{aligned} I(X; Y) &= H(X) + H(Y) - H(X, Y) \\ &= H(X) - H(X|Y) = H(Y) - H(Y|X) \end{aligned}$$

1.6 多元拓展与链式法则

以下拓展形式在后面章节中反复出现，必须熟练掌握。

1.6.1 条件互信息

定义 1.11 (条件互信息). 给定 Z 的条件下, X 与 Y 的互信息:

$$I(X; Y | Z) = H(X|Z) - H(X|Y, Z) = \sum_z p(z) \cdot I(X; Y | Z = z)$$

性质 1.12. (1) 非负性: $I(X; Y|Z) \geq 0$, 等号当且仅当 $X \rightarrow Z \rightarrow Y$ (X 与 Y 在给定 Z 下条件独立)

(2) 对称性: $I(X; Y|Z) = I(Y; X|Z)$

(3) $I(X; Y|Z) = 0 \iff X \perp\!\!\!\perp Y | Z$

1.6.2 互信息的链式法则

定理 1.13 (互信息的链式法则).

$$I(X; Y_1, Y_2, \dots, Y_n) = \sum_{i=1}^n I(X; Y_i | Y_1, \dots, Y_{i-1})$$

最常用的两变量情形:

$$I(X; Y, Z) = I(X; Z) + I(X; Y | Z) = I(X; Y) + I(X; Z | Y)$$

证明要点

[DPI 证明的核心一步] 利用链式法则的两种展开方式:

$$I(X; Y, Z) = \underbrace{I(X; Z)}_{\text{先抽 } Z} + \underbrace{I(X; Y|Z)}_{\text{再抽 } Y} = \underbrace{I(X; Y)}_{\text{先抽 } Y} + \underbrace{I(X; Z|Y)}_{\text{再抽 } Z}$$

当 $X \rightarrow Y \rightarrow Z$ 是马尔可夫链时, $I(X; Z|Y) = 0$, 从而 $I(X; Y) = I(X; Z) + I(X; Y|Z) \geq I(X; Z)$ 。这就是 DPI 的证明本质。

1.6.3 多元条件熵

定义 1.14 (多元条件熵).

$$H(X | Y_1, Y_2, \dots, Y_n) = \mathbb{E}_{X, Y^n} \left[\log \frac{1}{p(X | Y_1, \dots, Y_n)} \right]$$

性质 1.15 (熵率中用到的关键性质). (1) 条件增多, 熵不减: $H(X|Y_1) \geq H(X|Y_1, Y_2) \geq \dots \geq H(X|Y_1, \dots, Y_n)$

(2) $H(X|Y^n) \leq H(X|Y^{n-1}) \leq \dots \leq H(X)$

(3) 平稳过程中: $b_n = H(X_n|X_{n-1}, \dots, X_1)$ 单调递减有下界, 故极限存在 (熵率定义的基础)

1.6.4 联合熵的链式法则（多元形式）

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1})$$

联合熵的两种展开方式都常用：

$$\begin{aligned} H(X, Y, Z) &= H(X) + H(Y|X) + H(Z|X, Y) \\ &= H(Z) + H(Y|Z) + H(X|Y, Z) \end{aligned}$$

1.6.5 互信息与熵的完整关系图

多变量关系速查

$$\begin{aligned} I(X; Y|Z) &= H(X|Z) - H(X|Y, Z) \\ &= H(Y|Z) - H(Y|X, Z) \\ &= H(X|Z) + H(Y|Z) - H(X, Y|Z) \\ I(X; Y, Z) &= I(X; Z) + I(X; Y|Z) \\ &= I(X; Y) + I(X; Z|Y) \\ H(X|Y) &\geq H(X|Y, Z) \quad (\text{条件越多, 不确定性越小}) \\ I(X; Y) &\leq I(X; Y, Z) \quad (\text{更多的观测提供更多的信息}) \end{aligned}$$

1.6.6 条件 KL 散度

定义 1.16 (条件 KL 散度).

$$D_{\text{KL}}(p(y|x) \| q(y|x) | p(x)) \triangleq \sum_x p(x) \sum_y p(y|x) \log \frac{p(y|x)}{q(y|x)} = \sum_x p(x) \cdot D_{\text{KL}}(p(Y|X=x) \| q(Y|X=x))$$

即：先对每个 x 算 KL 散度，再用 $p(x)$ 加权平均。

非负性仍成立： $D_{\text{KL}}(p \| q | p(x)) \geq 0$ ，等号当且仅当 $p(y|x) = q(y|x)$ 对所有 x ($p(x) > 0$) 成立。

应用场景：信道容量 KKT 条件中， $\frac{\partial I}{\partial p_i} = D_{\text{KL}}(p(Y|X=x_i) \| p(Y)) - 1$ 就使用了 KL 散度的条件形式。

2 不等式与凹凸性

2.1 Jensen 不等式

若 f 为凸函数： $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$ 。若 f 严格凸，等号当且仅当 X 为常数。

常用函数

$f(x)$	凹凸性	Jensen 结论
x^2	凸	$\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$
$\log x$	凹	$\mathbb{E}[\log X] \leq \log \mathbb{E}[X]$
$x \log x$	凸	$\mathbb{E}[X \log X] \geq \mathbb{E}[X] \log \mathbb{E}[X]$
e^x	凸	$\mathbb{E}[e^X] \geq e^{\mathbb{E}[X]}$
$-\log x$	凸	$\mathbb{E}[-\log X] \geq -\log \mathbb{E}[X]$

Jensen 证明要点：凸函数总在其任一切平面上方，取 $x_0 = \mathbb{E}[X]$ 处切平面，两边取期望即得。

2.2 Log-sum 不等式

$$\sum_i a_i \log \frac{a_i}{b_i} \geq \left(\sum_i a_i \right) \log \frac{\sum_i a_i}{\sum_i b_i}$$

等号当且仅当 $\frac{a_i}{b_i} = \text{constant}$ 。

两种证明方式：用 $\log x$ （凹）或 $x \log x$ （凸）配合 Jensen 不等式。

2.3 KL 散度非负性（Gibbs 不等式）

$D_{\text{KL}}(p||q) \geq 0$ ，等号当且仅当 $p = q$ 。

证明方法：(1) Log-sum 不等式，直接代入 $a_x = p(x), b_x = q(x)$ ；(2) Jensen 不等式，利用 $-\log x$ 的凸性：

$$D_{\text{KL}}(p||q) = \mathbb{E}_p \left[-\log \frac{q}{p} \right] \geq -\log \mathbb{E}_p \left[\frac{q}{p} \right] = -\log 1 = 0$$

2.4 重要推论

- 均匀分布熵最大： $H(p) \leq \log |\mathcal{X}|$ ，证明 $H(p) = \log |\mathcal{X}| - D_{\text{KL}}(p||u)$
- 互信息非负： $I(X;Y) = D_{\text{KL}}(p_{XY}||p_X p_Y) \geq 0$
- 条件熵不大于原熵： $H(X|Y) \leq H(X)$
- $H(X) + H(Y) \geq H(X,Y)$
- 混合分布增加熵： $H(\lambda p_1 + (1-\lambda)p_2) \geq \lambda H(p_1) + (1-\lambda)H(p_2)$

2.5 凹凸性总结

凹凸性速查

函数	凹凸性
$D_{\text{KL}}(p\ q)$	关于 (p, q) 为凸函数
$H(p)$ (熵)	关于 p 为凹函数
$I(X; Y)$ 给定 $p(Y X)$	关于 $p(X)$ 为凹函数
$I(X; Y)$ 给定 $p(X)$	关于 $p(Y X)$ 为凸函数

证明方法：

- KL 散度凸性 $\rightarrow$ Log-sum 不等式；
- 熵的凹性 $\rightarrow$ Log-sum/Jensen/条件熵三种证法；
- 互信息关于 $p(X)$ 凹 $\rightarrow H(Y)$ 是 $p(X)$ 的凹函数 ($p(y)$ 是 $p(x)$ 的线性组合 + 凹函数与线性函数的复合仍为凹)；
- 互信息关于 $p(Y|X)$ 凸 $\rightarrow$ 利用 KL 散度的凸性。

3 渐进均分性 (AEP) ——独立同分布

3.1 理论准备

大数定理: $X_i \stackrel{\text{i.i.d.}}{\sim} p(x)$, $\frac{1}{n} \sum X_i \xrightarrow{p} \mathbb{E}[X]$ 。

切比雪夫不等式: $P(|X - \mu| \geq \epsilon) < \frac{\sigma^2}{n\epsilon^2}$ 。

3.2 AEP 与典型集

定义 3.1 (AEP).

$$-\frac{1}{n} \log p(X^n) = \frac{1}{n} \sum_{i=1}^n -\log p(X_i) \xrightarrow{p} H(X)$$

定义 3.2 (ϵ -典型集).

$$A_\epsilon^{(n)} \triangleq \left\{ x^n \in \mathcal{X}^n : \left| \frac{1}{n} \log \frac{1}{p(x^n)} - H(X) \right| \leq \epsilon \right\}$$

定理 3.3 (典型集性质). 当 $n \rightarrow \infty$:

- (1) $p(X^n \in A_\epsilon^{(n)}) \rightarrow 1$
- (2) $(1 - \epsilon)2^{n(H(X) - \epsilon)} \leq |A_\epsilon^{(n)}| \leq 2^{n(H(X) + \epsilon)}$
- (3) $\forall x^n \in A_\epsilon^{(n)} : 2^{-n(H(X) + \epsilon)} \leq p(x^n) \leq 2^{-n(H(X) - \epsilon)}$

证明要点

性质 (2) 的证明——注意上下界的不对称性：

$$\text{上界 (对所有 } n \text{ 成立): } 1 \geq \sum_{x^n \in A} p(x^n) \geq |A| \cdot 2^{-n(H+\epsilon)} \Rightarrow |A| \leq 2^{n(H+\epsilon)}$$

$$\text{下界 (需 } n \text{ 充分大): } 1 - \epsilon \leq \sum_{x^n \in A} p(x^n) \leq |A| \cdot 2^{-n(H-\epsilon)} \Rightarrow |A| \geq (1 - \epsilon)2^{n(H-\epsilon)}$$

关键区别：上界推导只用 $1 \geq \sum_A p$ ，始终成立；下界需要 $P(A) \geq 1 - \epsilon$ ，依赖于 AEP 收敛 (n 充分大)。定理中常用同一个 ϵ 书写，但下界的 $(1 - \epsilon)$ 实际是概率松弛量，与典型集定义中的熵容差 ϵ 来源不同。

$$\text{典型集占总序列比例: } \frac{|A_\epsilon^{(n)}|}{|\mathcal{X}^n|} \approx \frac{2^{nH(X)}}{2^{n \log |\mathcal{X}|}} = \frac{1}{2^{nD_{\text{KL}}(p_X \| u_X)}}$$

 $D_{\text{KL}}(p \| u)$ 的直观含义

- $H(X)$: 数据的不可压缩性——熵越大，无损压缩越困难
- $D_{\text{KL}}(p_X \| u_X)$: 数据的可压缩性——KL 散度越大 (分布越不均匀)，典型集在总序列中的占比指数级缩小，可压缩空间越大
- 极端情形：当 $p_X = u_X$ (均匀分布) 时， $D_{\text{KL}} = 0$ ， $A_\epsilon^{(n)} = \mathcal{X}^n$ (所有序列都典型)，无法压缩

3.2.1 典型集的最小性

定理 3.4 (典型集是渐近最小的“高概率集合”)。设 $B_n \subseteq \mathcal{X}^n$ 满足 $|B_n| \leq 2^{n(H(X)-\delta)}$ ($\delta > 0$)，则当 $n \rightarrow \infty$ 时：

$$P(X^n \in B_n) \rightarrow 0$$

即：任何大小严格小于 $2^{nH(X)}$ 的集合，其概率必趋于零。

证明要点

取 $\epsilon < \delta$ ，将 B_n 拆分为典型部分 + 非典型部分：

$$\begin{aligned} P(X^n \in B_n) &= P(X^n \in B_n \cap A_\epsilon^{(n)}) + P(X^n \in B_n \cap (A_\epsilon^{(n)})^c) \\ &\leq \sum_{x^n \in B_n \cap A} p(x^n) + P(X^n \notin A_\epsilon^{(n)}) \\ &\leq |B_n| \cdot 2^{-n(H-\epsilon)} + \underbrace{P(X^n \notin A_\epsilon^{(n)})}_{\rightarrow 0} \\ &\leq 2^{n(H-\delta)} \cdot 2^{-n(H-\epsilon)} + \epsilon = 2^{-n(\delta-\epsilon)} + \epsilon \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

推论：典型集 $A_\epsilon^{(n)}$ 在概率意义下是“最小”的高概率集合——任何概率接近 1 的集合，大小至少为 $(1 - \epsilon)2^{n(H-\epsilon)}$ 。

3.2.2 典型集内概率真的“等分”吗？

渐近等分不等于概率均等

典型集内最大概率与最小概率之比：

$$\frac{p_{\max}}{p_{\min}} \approx \frac{2^{-n(H-\epsilon)}}{2^{-n(H+\epsilon)}} = 2^{2n\epsilon}$$

- 概率差距是指数级的 ($2^{2n\epsilon}$, 随 n 急剧增长)
- 但信息量 $-\log p(x^n)$ 的差距只是线性的 ($2n\epsilon$)
- “等分性”指的是信息量 ($-\frac{1}{n} \log p$) 趋近相等, 而非概率本身相等

3.2.3 二项分布视角

对于 Bernoulli(p) 信源, n 次试验中 1 出现 k 次的概率为 $\binom{n}{k} p^k (1-p)^{n-k}$ 。AEP 表明: 当 n 足够大时, 概率质量集中在 $k \approx n \cdot \mathbb{E}[X] = np$ 附近。AEP 将二项分布中观察到的“概率向期望集中”现象, 推广到了任意 i.i.d. 信源。

3.3 信源定长编码定理

定理 3.5 (信源定长编码定理). 记 $S_\delta \subseteq \mathcal{X}^n$ 为误差在 δ 内 (即 $P(X^n \in S_\delta) \geq 1 - \delta$) 的最小集合。对任意 $\epsilon > 0$ 和 $0 < \delta < 1$, 存在 n_0 , 当 $n > n_0$ 时:

$$\left| \frac{1}{n} \log_2 |S_\delta| - H(X) \right| < \epsilon$$

即: 编码长度 $\approx nH(X)$ bit, 误差可任意小。

证明要点

[证明思路] 上界方向 (编码长度 $\leq nH + n\epsilon$):

取 n_0 使 $\frac{\sigma^2}{n_0 \epsilon^2} \leq \delta$ (Chebyshev)。对典型集编码, 需 $\log_2 |A_\epsilon^{(n)}| \leq n(H + \epsilon)$ bit。因 $P(A_\epsilon^{(n)}) \geq 1 - \delta$, S_δ 不比 $A_\epsilon^{(n)}$ 更大:

$$\frac{1}{n} \log_2 |S_\delta| \leq \frac{1}{n} \log_2 |A_\epsilon^{(n)}| \leq H(X) + \epsilon$$

下界方向 (编码长度 $\geq nH - n\epsilon$):

若 $|S_\delta| < 2^{n(H-\epsilon)}$, 则 $P(X^n \in S_\delta) \rightarrow 0$ (由典型集最小性), 与 $P(S_\delta) \geq 1 - \delta > 0$ 矛盾。故 $|S_\delta| \geq 2^{n(H-\epsilon)}$, 即 $\frac{1}{n} \log_2 |S_\delta| \geq H(X) - \epsilon$ 。

编码方案: 1 位前缀区分典型/非典型——前缀“1”+ 典型集索引 ($nH + n\epsilon$ bit), 前缀“0”+ 原始序列。误差概率 $\leq \delta$ 。

4 Kraft 不等式与变长编码

4.1 编码分类与关系

非奇异码 $\supset$ 唯一可译码 $\supset$ 即时码/前缀码

- 前缀码 $\Leftrightarrow$ 即时码（两概念等价）
- 前缀码是唯一可译码
- 任意唯一可译码都存在等优前缀码 $\rightarrow$ 符号编码只考虑前缀码

4.2 Kraft-McMillan 不等式

定理 4.1 (Kraft 不等式). 存在 D 进制前缀码 $\Leftrightarrow \sum_{x \in \mathcal{X}} D^{-l(x)} \leq 1$ 。

定理 4.2 (McMillan 不等式). 任意唯一可译码 $\Rightarrow \sum_{x \in \mathcal{X}} D^{-l(x)} \leq 1$ 。

核心结论

前缀码已有的码长组合，任何唯一可译码都无法超越。
符号编码只需考虑前缀码，不损失最优性。

证明要点

[Kraft 充分性证明] 构造概率 $p^*(x) = 2^{-l(x)}$ ，若 $\sum p^*(x) < 1$ ，补足缺失概率为二分布，利用二分布构造前缀树。

证明要点

[Kraft 必要性证明] 考虑深度为 l_{max} 的完全二叉树。码长为 l_i 的叶节点独占 $2^{l_{max}-l_i}$ 个底层节点。各子树不相交：

$$\sum_{i=1}^m 2^{l_{max}-l_i} \leq 2^{l_{max}} \Rightarrow \sum 2^{-l_i} \leq 1$$

4.3 最优编码长度

定理 4.3 (最优编码长度——连续松弛).

$$\min \sum p(x)l(x), \quad s.t. \quad \sum D^{-l(x)} \leq 1$$

最优解： $l^*(x) = -\log_D p(x)$ ，平均码长 $L^* = H_D(X)$ 。

两种证法：(1) Lagrange 乘子法；(2) KL 散度非负：

$$\sum p_i l_i = \sum p_i \log_D \frac{1}{q_i} - \log_D z \geq \sum p_i \log_D \frac{1}{p_i} = H_D(X)$$

其中 $q_i = D^{-l_i}/z$ ， $z = \sum D^{-l_i}$ 。

4.4 变长码编码定理与编码开销

定理 4.4 (变长码编码定理). 存在前缀码使得:

$$H(X) \leq L < H(X) + 1$$

取 $l(x) = \lceil -\log p(x) \rceil$ 即证存在性。

若用分布 q 编码真实分布 p : $L_q = D_{\text{KL}}(p||q) + H(p) = D_{\text{KL}}(p||q) + L^*$ 。

5 Huffman 最优前缀码

5.1 Huffman 算法

1. 取概率最小的两个符号, 赋予最后一位不同、其余位相同的码字;
2. 将两符号融合为概率和的新符号;
3. 重复直到只剩一个符号。

5.2 最优性证明

1. 最优前缀码中, 概率最小的两个符号 $l_{r-1} = l_r = l_{\max}$ (姊妹对);
2. 融合 $\rightarrow$ 扩展关系: $L_U = L_V + p_{r-1} + p_r$;
3. 原问题 U 的最优性 $\Leftrightarrow$ 子问题 V 的最优性;
4. 递归至两个符号 (基础情形: 编码为 0 和 1), 得证。

整数约束优化

$$\min \sum p(x)l(x), \quad s.t. \sum 2^{-l(x)} \leq 1, l(x) \in \mathbb{Z}^+$$

Huffman 码 = 该整数规划的最优解; Shannon 码 = 近似解。

5.3 块编码

N 次扩展信源: 将长为 N 的序列视为一个整体符号。

$$\frac{1}{N}H(X^N) \leq L_{\text{Huffman}} < \frac{1}{N}H(X^N) + \frac{1}{N}$$

6 AEP ——平稳遍历过程

6.1 平稳过程

定义 6.1 (平稳过程).

$$p(X_1 = x_1, \dots, X_n = x_n) = p(X_k = x_1, \dots, X_{n+k} = x_n)$$

联合概率分布具有时间平移不变性。

6.2 熵率的存在性与等价性

令 $b_n = H(X_n | X_{n-1}, \dots, X_1)$ 。由平稳性, b_n 单调递减且有下界 0, 故极限存在:

$$H'(\mathcal{X}) \triangleq \lim_{n \rightarrow \infty} H(X_n | X_{n-1}, \dots, X_1)$$

由 Cesàro 定理: 若 $\lim b_n = b$, 则 $\lim \frac{1}{n} \sum_{i=1}^n b_i = b$ 。

定理 6.2 (熵率的等价性).

$$\lim_{n \rightarrow \infty} \frac{1}{n} H(X^n) = \lim_{n \rightarrow \infty} H(X_n | X_1^{n-1}) = H(X_0 | X_{-\infty}^{-1})$$

证明要点

$$\frac{1}{n} H(X^n) = \frac{1}{n} \sum_{i=1}^n \underbrace{H(X_i | X^{i-1})}_{=b_i} \xrightarrow{\text{Cesàro}} H'(\mathcal{X})$$

熵率含义: 已知无限长历史的条件下, 当前符号残存的不确定性。

6.3 平稳马尔可夫过程

平稳马尔可夫过程是最简单的非独立信源模型: 平稳性保证时间不变性, 马尔可夫性保证依赖关系仅向前回溯一步。

6.3.1 状态转移矩阵

定义 6.3 (状态转移矩阵). 对状态空间 $\mathcal{S} = \{s_1, \dots, s_m\}$ (同时也是信源符号集 $\mathcal{X}$), 定义:

$$P_{ij} \triangleq p(X_0 = s_j | X_{-1} = s_i), \quad P \in \mathbb{R}^{m \times m}$$

性质 6.4 (状态转移矩阵的性质). (1) 所有元素非负: $P_{ij} \geq 0$

(2) 每行之和为 1: $\sum_j P_{ij} = 1$ (行随机矩阵)

链式法则 (描述随机过程演化):

$$p(X_0) = p(X_{-1})P \iff p(X_0 = s_j) = \sum_{i=1}^m p(X_{-1} = s_i) P_{ij}$$

6.3.2 k 步转移与 Chapman-Kolmogorov 方程

定义 6.5 (k 步转移矩阵). k 步转移矩阵 $P^{(k)}$ 的元素 $P_{ij}^{(k)} \triangleq p(X_k = s_j | X_0 = s_i)$, 满足:

$$P^{(k)} = P^k \quad (\text{矩阵 } k \text{ 次幂})$$

由马尔可夫性:

$$p(X_k) = p(X_0)P^k$$

即: 初始分布右乘 P^k 即得 k 步后的分布。

性质 6.6 (Chapman-Kolmogorov 方程).

$$P_{ij}^{(m+n)} = \sum_k P_{ik}^{(m)} P_{kj}^{(n)} \iff P^{m+n} = P^m \cdot P^n$$

(从 i 出发经过 $m+n$ 步到达 j , 等价于先走 m 步到某个 k , 再走 n 步到 j 。)

6.3.3 稳态分布

定义 6.7 (稳态分布). 若分布 $\mathbf{u} = (u_1, \dots, u_m)$ 满足 $\mathbf{u} = \mathbf{u}P$ (即 $\mathbf{u}$ 是 P 关于特征值 1 的左特征向量), 则称 $\mathbf{u}$ 为稳态分布。若初始分布 $p(X_0) = \mathbf{u}$, 则对所有 k 有 $p(X_k) = \mathbf{u}$ 。

Detailed Balancing (细致平衡)

充分条件: 若存在分布 $\mathbf{u}$ 满足对所有 i, j :

$$u_i P_{ij} = u_j P_{ji}$$

则 $\mathbf{u}$ 是稳态分布。

验证: $\sum_i u_i P_{ij} = \sum_i u_j P_{ji} = u_j \sum_i P_{ji} = u_j$, 即 $\mathbf{u} = \mathbf{u}P$ 。

6.3.4 平稳马尔可夫链的熵率

定理 6.8 (马尔可夫链的熵率). 对于稳态分布为 $\mathbf{u}$ 的平稳马尔可夫链:

$$\begin{aligned} H(\mathcal{X}) &= H(X_0 | X_{-1}) = \sum_{i=1}^m u_i \cdot H(X_0 | X_{-1} = s_i) \\ &= \sum_{i=1}^m u_i \sum_{j=1}^m P_{ij} \log \frac{1}{P_{ij}} \end{aligned}$$

证明要点

平稳马尔可夫性: $H(X_0 | X_{-1}, X_{-2}, \dots) = H(X_0 | X_{-1})$ (马尔可夫性使条件只回溯一步)。
熵率 $H(\mathcal{X}) = \lim H(X_n | X^{n-1}) = H(X_0 | X_{-1})$ (由平稳性)。

6.3.5 完整计算实例 (4 状态链)

课件中的两比特马尔可夫链实例:

状态空间 $\mathcal{S} = \{00, 01, 10, 11\}$ (4 个状态), 转移矩阵:

$$P = \begin{bmatrix} 0.8 & 0.2 & 0 & 0 \\ 0 & 0 & 0.5 & 0.5 \\ 0.5 & 0.5 & 0 & 0 \\ 0 & 0 & 0.2 & 0.8 \end{bmatrix}$$

稳态分布: $\mathbf{u} = (\frac{5}{14}, \frac{1}{7}, \frac{1}{7}, \frac{5}{14})$ (解 $\mathbf{u} = \mathbf{u}P$)。

熵率计算——对每个状态分别计算条件熵，再加权：

$$\begin{aligned} H(\mathcal{X}) &= \frac{5}{14}H(0.8, 0.2) + \frac{1}{7}H(0.5, 0.5) + \frac{1}{7}H(0.5, 0.5) + \frac{5}{14}H(0.8, 0.2) \\ &= \frac{5}{14} \times 0.722 + \frac{2}{7} \times 1.000 + \frac{5}{14} \times 0.722 \\ &\approx 0.80 \text{ bit/符号} \end{aligned}$$

6.4 遍历性

定义 6.9 (遍历性条件). 有限状态马尔可夫链：

不可约性 (Irreducibility) + 非周期性 (Aperiodicity) $\Rightarrow$ 遍历性 (Ergodicity)

遍历性意味着：时间平均 = 空间平均（样本平均 $\xrightarrow{P}$ 概率期望）。

6.4.1 不可约性 (Irreducibility)

- **定义：** 对任意 i, j ，存在正整数 N 使 $P_{ij}^N > 0$
- **图解释：** 在状态转移图（若 $P_{ij} > 0$ 则连边 $i \rightarrow j$ ）中，任意两节点间存在有向路径
- **Perron-Frobenius 定理：** 对有限状态不可约矩阵：
 - 存在唯一稳态分布 $\mathbf{u}$
 - $\mathbf{u}$ 的所有元素严格大于 0

6.4.2 非周期性 (Aperiodicity)

定义 6.10 (周期与非周期). 状态 s 的**周期** $d(s)$ ：从 s 出发再回到 s 的所有可能步数的最大公约数：

$$d(s) = \gcd\{k \geq 1 : P_{ss}^{(k)} > 0\}$$

若 $d(s) = 1$ ，称状态 s 是**非周期**的。

性质 6.11 (不可约链的周期性质). 在不可约链中，所有状态具有相同的周期。

（证明思路：取 $i \rightarrow j$ 路径（长 a ）和 $j \rightarrow i$ 路径（长 b ），构造 $i \rightarrow i$ 回路（长 $a+b$ ），再取 $j \rightarrow j$ 的任意回路（长 n ），构造 $i \rightarrow i$ 的另一回路（长 $a+n+b$ ）。两回路长度的差为 n ，故 $d(i) \mid d(j)$ 。由对称性 $d(i) = d(j)$ 。）

非周期性的实用判据

对不可约链，只需检查一个状态：

- 若 $P_{ii} > 0$ （对角元 > 0 ，即图中存在自环），则 $d(i) = 1$ ，整个链非周期
- 更一般地：若某个 $P_{ii}^{(k)} > 0$ 且 $P_{ii}^{(k+1)} > 0$ ，则周期必为 1

6.4.3 平稳遍历的层次关系

独立同分布 (i.i.d.) $\subset$ 平稳遍历过程 $\subset$ 平稳过程

- i.i.d.: 最强假设——大数定理 + AEP
- 平稳遍历 (含平稳遍历马尔可夫链): Birkhoff 遍历定理 + SMB 定理
- 一般的平稳过程: 熵率存在但不一定有 AEP

6.5 Shannon-McMillan-Breiman 定理

定理 6.12 (SMB 定理). 对平稳遍历过程, 当 $n \rightarrow \infty$:

$$\frac{1}{n} \log \frac{1}{p(X^n)} \xrightarrow{p} H(X_0 | X_{-\infty}^{-1}) = H(\mathcal{X})$$

证明要点

[证明思路] 利用平稳性将 $-\frac{1}{n} \log p(X^n)$ 改写为条件信息量的 Cesàro 平均:

$$\frac{1}{n} \log \frac{1}{p(X^n)} = \frac{1}{n} \sum_{i=1}^n \log \frac{1}{p(X_0 | X_{1-i}^{-1})}$$

由 Birkhoff 遍历定理 (大数定理在平稳遍历过程的推广), 当 $n \rightarrow \infty$ 时该 Cesàro 平均收敛到期望 $H(X_0 | X_{-\infty}^{-1})$ 。

注: 本节 SMB 定理仅需了解结论, 不考证明。Birkhoff 遍历定理不考。

7 数据处理不等式与 Fano 不等式

7.1 马尔可夫链

$X \rightarrow Y \rightarrow Z$: $p(x, y, z) = p(x)p(y|x)p(z|y)$ 。性质: (1) 给定现在, 过去与未来条件独立; (2) 可逆: $X \rightarrow Y \rightarrow Z \iff Z \rightarrow Y \rightarrow X$ 。

7.2 数据处理不等式 (DPI)

定理 7.1 (数据处理不等式). 若 $X \rightarrow Y \rightarrow Z$, 则:

$$I(X; Y) \geq I(X; Z) \quad (DPI)$$

$$I(Y; Z) \geq I(X; Z) \quad (Reverse \text{ DPI})$$

证明要点

[DPI 证明] 利用互信息的链式法则展开两种方式：

$$\begin{aligned} I(X; Y, Z) &= I(X; Z) + I(X; Y|Z) \\ &= I(X; Y) + \underbrace{I(X; Z|Y)}_{=0 \text{ (Markov)}} = I(X; Y) \end{aligned}$$

故 $I(X; Y) - I(X; Z) = I(X; Y|Z) \geq 0$ 。

含义：数据处理只会丢失信息，无法增加信息。

等号条件：DPI 等号 $\iff I(X; Y|Z) = 0 \iff X \rightarrow Z \rightarrow Y$ 也是马尔可夫链。

7.3 充分统计量

7.3.1 因子分解定理（核心基础）

定理 7.2 (Neyman-Fisher 因子分解定理). $T(X)$ 是参数 θ 的充分统计量的充要条件：联合概率密度可分解为

$$f(x; \theta) = h(x) \cdot g(T(x); \theta)$$

其中：

- $h(x)$ ：与 θ 无关（只依赖于数据本身的结构）
- $g(T(x); \theta)$ ：可以依赖 θ ，但对数据的依赖仅通过 $T(x)$

即： θ 接触到数据的唯一“通道”就是 $T(x)$ 。

因子分解 = 充分性的操作型定义。考试中判断一个统计量是否充分，最直接的方法就是做因子分解。

7.3.2 从因子分解到条件分布与 θ 无关

从因子分解出发，可以直接推导为什么 $p(X|T=t, \theta)$ 与 θ 无关。

$T(X)$ 的边缘分布为（在曲面 $T(x) = t$ 上积分）：

$$f_T(t; \theta) = \int_{x: T(x)=t} f(x; \theta) dx = \int_{x: T(x)=t} h(x) \cdot g(t; \theta) dx = g(t; \theta) \cdot \underbrace{\int_{x: T(x)=t} h(x) dx}_{\text{只与 } t \text{ 有关, 与 } \theta \text{ 无关}}$$

条件分布：

$$p(X = x | T = t, \theta) = \frac{f(x; \theta)}{f_T(t; \theta)} = \frac{h(x) \cdot g(t; \theta)}{g(t; \theta) \cdot \int_{T(x)=t} h(x) dx} = \frac{h(x)}{\int_{T(x)=t} h(x) dx}$$

$g(t; \theta)$ 在分子分母中精确约掉了。条件分布退化为只依赖于 $h(x)$ 的形式，而 $h(x)$ 本就不含 θ 。这就是“条件分布与 θ 无关”的数学本质。

关键洞察： $T(X)$ 本身当然可以依赖于 θ （它的边际分布 $f_T(t; \theta)$ 包含 g ），但一旦你固定了 $T(X) = t$ ， $(X | T = t)$ 的分布就不再给 θ 留下任何“额外通道”——数据关于 θ 的全部信息已经被 $T(X)$ 的值 t 完全捕获。

7.3.3 高斯实例：走一遍完整推导

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\theta, 1)$, $T(X) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

Step 1: 因子分解。 利用 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$:

$$f(x; \theta) \propto \exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2\right) = \underbrace{\exp\left(-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2\right)}_{h(x)} \cdot \underbrace{\exp\left(-\frac{n}{2} (\bar{x} - \theta)^2\right)}_{g(T(x); \theta)}$$

$h(x)$ 只涉及“各数据点围绕自身均值的离散程度”，与 θ 完全无关。 θ 只通过 $\bar{x} = T(x)$ 进入。

Step 2: 确认 T 是充分统计量。 因子分解已直接给出—— $\bar{X}$ 是 θ 的充分统计量。

Step 3: 验证条件分布与 θ 无关。 $\bar{X} \sim \mathcal{N}(\theta, 1/n)$, $f_T(t; \theta) \propto \exp(-\frac{n}{2}(t - \theta)^2)$ 。条件分布:

$$p(X = x \mid \bar{X} = t, \theta) = \frac{\exp(-\frac{1}{2} \sum (x_i - \bar{x})^2) \cdot \exp(-\frac{n}{2}(t - \theta)^2)}{\exp(-\frac{n}{2}(t - \theta)^2) \cdot \int_{\bar{x}=t} \exp(-\frac{1}{2} \sum (x_i - \bar{x})^2) dx}$$

$g(t; \theta)$ 约掉，结果与 θ 无关。

直观理解：一旦知道了样本均值 $\bar{x} = t$ ，各数据点围绕 t 的残差分布是均值为 0 的纯噪声——这个纯噪声不包含任何关于 θ 的额外信息。 $T(X) = \bar{X}$ 本身虽然是 θ 的带噪估计（方差 $1/n$ ），但它已经把 X 中关于 θ 的信息榨干了。

7.3.4 三种等价表述

充分统计量有三种等价刻画，分别从不同视角描述同一件事：

1. **经典统计视角：** $p(X \mid T(X) = t, \theta)$ 与 θ 无关。给定 $T(X) = t$ 后， X 的残差分布不包含 θ —— θ 对 X 的影响完全被 $T(X)$ 的值 t 中介了。（上节已从因子分解推导。）
2. **贝叶斯视角：** $p(\theta \mid T(X)) = p(\theta \mid X)$ 。关于 θ 的后验分布，用 $T(X)$ 和用全部 X 得到的结果完全一样。换言之，只看压缩后的统计量就够了，看原始数据不会改变你对 θ 的任何信念。
3. **信息论视角：** $I(\theta; T(X)) = I(\theta; X)$ 。 $T(X)$ 对 X 做“无损压缩”——压缩后不丢失关于 θ 的任何信息。

贝叶斯视角 $\Rightarrow$ 信息论视角（最直观的推导）：

$p(\theta \mid X) = p(\theta \mid T)$ 等价于 $\theta \perp\!\!\!\perp X \mid T$ ，即 $I(\theta; X \mid T) = 0$ 。互信息的链式法则给出：

$$I(\theta; X) = I(\theta; T) + \underbrace{I(\theta; X \mid T)}_{=0} = I(\theta; T)$$

推导是双向的（互信息为零 $\iff$ 条件独立 $\iff$ 后验相等），所以三者完全等价。

考试操作：因子分解 $\rightarrow$ 条件分布与 θ 无关，这是判断充分性最直接的方法。后验等价提供最直观的理解（“看 T 就够了，不用看原始数据”），信息论等式是 DPI 部分的自然语言。

7.3.5 指数族分布与充分统计量

定义 7.3 (指数族分布). 概率密度/质量函数可写成如下形式的分布:

$$p(x; \theta) = h(x) \cdot \exp(\eta(\theta)^T \tau(x) - A(\theta))$$

其中:

- $\tau(x)$: 自然充分统计量 (natural sufficient statistic)
- $\eta(\theta)$: 自然参数 (natural parameter)
- $A(\theta)$: 对数配分函数 (log-partition function), 保证归一化
- $h(x)$: 底测度 (base measure), 与 θ 无关

指数族天然满足因子分解: 直接令 $h(x)$ 如上、 $g(T; \theta) = \exp(\eta(\theta)^T T - A(\theta))$ 即可。因此, 对于指数族, $\tau(x)$ 可以直接读出, 无需推导。

指数族的充分统计量判断方法

对于 i.i.d. 样本 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} p(x; \theta)$, 联合密度为:

$$f(x_1, \dots, x_n; \theta) = \underbrace{\prod_{i=1}^n h(x_i)}_{h(x_1, \dots, x_n)} \cdot \exp\left(\eta(\theta)^T \underbrace{\sum_{i=1}^n \tau(x_i)}_{T(X_1, \dots, X_n)} - nA(\theta)\right)$$

判断步骤:

1. 将分布写成 $p(x; \theta) = h(x) \cdot \exp(\eta(\theta)^T \tau(x) - A(\theta))$ 形式;
2. 读出 $\tau(x)$ ——这就是单个样本的自然充分统计量;
3. 对于 n 个 i.i.d. 样本: $T(X_1, \dots, X_n) = \sum_{i=1}^n \tau(X_i)$ 。

关键结论: $\sum_{i=1}^n \tau(X_i)$ 是指数族分布中参数 θ 的充分统计量。

7.3.6 常见指数族分布的充分统计量

分布	指数族形式	$\tau(x)$
Bernoulli	$\exp(x \log \frac{\theta}{1-\theta} + \log(1-\theta))$	x
Poisson	$\frac{1}{x!} \exp(x \log \lambda - \lambda)$	x
Gaussian (σ^2 已知)	$\exp(\frac{\mu}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2))$	x
Gaussian (μ, σ^2 均未知)	同上, $\eta = (\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2})^T$	$(x, x^2)^T$
Exponential	$\lambda \exp(-\lambda x) = \exp(-\lambda x + \log \lambda)$	x
Beta	$\exp((\alpha-1) \log x + (\beta-1) \log(1-x) - \log B(\alpha, \beta))$	$(\log x, \log(1-x))^T$

7.3.7 判断与证明方法总结

1. 验证充分性 (因子分解法): 将联合密度写成 $f(x; \theta) = h(x) \cdot g(T(x); \theta)$, 其中 g 只通过 $T(x)$ 依赖数据。若成功分解, 则 T 充分。

2. 找指数族的充分统计量：将分布写成 $p(x; \theta) \propto \exp(\eta(\theta)^T \tau(x))$ 形式， $\tau(x)$ 即自然充分统计量。
3. 验证非充分性：若能找到两个不同 θ 值下、相同 T 值的条件分布不同，或无法做因子分解，则 T 不充分。
4. 互信息判定（信息论视角）： T 充分 $\iff I(\theta; X) = I(\theta; T(X)) \iff \theta \rightarrow T(X) \rightarrow X$ 是马尔可夫链。

7.4 Fano 不等式

对马尔可夫链 $X \rightarrow Y \rightarrow \hat{X}$ ，定义误差 $E = \mathbf{1}[X \neq \hat{X}]$ ， $P_e = P(E = 1)$ 。

定理 7.4 (Fano 不等式)。

$$H(X|Y) \leq H(X|\hat{X}) \leq H(E) + P_e \cdot H(X) \leq 1 + P_e \cdot H(X)$$

Fano 不等式——误差下界

$$P_e \geq \frac{H(X|Y) - 1}{H(X)} \geq \frac{H(X|Y) - 1}{\log |\mathcal{X}|}$$

证明要点

[Fano 不等式证明] 利用联合熵的链式法则两次展开 $H(E, X|\hat{X})$ ：

$$H(E, X|\hat{X}) = H(X|\hat{X}) + \underbrace{H(E|X, \hat{X})}_{=0} = H(E|\hat{X}) + H(X|E, \hat{X})$$

展开 $H(X|E, \hat{X}) = (1 - P_e) \underbrace{H(X|\hat{X}, E=0)}_{=0} + P_e \cdot H(X|\hat{X}, E=1)$,

代入并利用 $H(E|\hat{X}) \leq H(E) \leq 1$ 和 $H(X|\hat{X}, E=1) \leq H(X)$ 得证。

8 噪声信道编码定理与联合典型性

8.1 通信系统模型

- 离散无记忆信道 (DMC)： $P_{Y^n|X^n}(y^n|x^n) = \prod_{i=1}^n P_{Y|X}(y_i|x_i)$
每次使用信道相互独立，输入 X_i 仅影响对应的输出 Y_i
- 编码方案 $C_n = (\text{编码器 } u \rightarrow x^n(u), \text{译码器 } y^n \rightarrow \hat{u})$
编码器将 M 个消息映射为 n 长码字；译码器根据信道输出估计消息
- 传输率： $R = \frac{\log_2 M}{n}$ (bits/channel use)
 n 越大则码字 x^n 越长，传输率越低； M 越大传输率越高
- 传输错误概率： $P_e^{(n)} = P(\hat{U} \neq U | C_n)$ ，取决于编码方案的好坏
- 核心问题：给定 DMC，最大可达传输率是多少？

8.2 噪声信道编码定理

定理 8.1 (Shannon 1948). 对于离散无记忆噪声信道, 最大可达传输率:

$$R_{max} = \max_{P_X} I(X; Y) \triangleq C \quad (\text{信道容量})$$

- 正向 (可达性): 若 $R < C$, 则存在编码方案 C_n 使 $P_e^{(n)} \rightarrow 0$ ($n \rightarrow \infty$);
- 反向 (不可达性): 若 $R > C$, 则任何编码方案都有 $P_e^{(n)} > 0$ 。

即: $\max_{P_X} I(X; Y)$ 既是理论上可计算的量, 又是实际可操作的最大传输率。

8.3 联合典型集

8.3.1 定义与基本性质

定义 8.2 (联合典型集).

$$A_\epsilon^{(n)}(X, Y) \triangleq \left\{ (x^n, y^n) : \begin{cases} \left| \frac{1}{n} \log \frac{1}{p(x^n)} - H(X) \right| \leq \epsilon \\ \left| \frac{1}{n} \log \frac{1}{p(y^n)} - H(Y) \right| \leq \epsilon \\ \left| \frac{1}{n} \log \frac{1}{p(x^n, y^n)} - H(X, Y) \right| \leq \epsilon \end{cases} \right\}$$

解读: 一个序列对 (x^n, y^n) 是联合典型的, 当且仅当: x^n 自身是 P_X 的典型序列 且 y^n 自身是 P_Y 的典型序列 且 (x^n, y^n) 联合是 P_{XY} 的典型序列。

性质 8.3. (1) 若 $(X^n, Y^n) \stackrel{i.i.d.}{\sim} P_{XY}$ (联合采样), 则 $P((x^n, y^n) \in A_\epsilon^{(n)}) \xrightarrow{n \rightarrow \infty} 1$
 (2) 对所有 n : $|A_\epsilon^{(n)}| \leq 2^{n(H(X, Y) + \epsilon)}$

8.3.2 联合典型引理 (Joint Typicality Lemma)

这是正向证明中控制错误概率的核心引理。

定理 8.4 (Joint Typicality Lemma). 设 $\tilde{X}^n \stackrel{i.i.d.}{\sim} P_X$ 与 $\tilde{Y}^n \stackrel{i.i.d.}{\sim} P_Y$ 相互独立生成 ($\tilde{X}^n \perp\!\!\!\perp \tilde{Y}^n$), 其中 P_X, P_Y 分别是 P_{XY} 的边缘分布。则:

$$P((\tilde{x}^n, \tilde{y}^n) \in A_\epsilon^{(n)}(X, Y)) \leq 2^{-n(I(X; Y) - 3\epsilon)}$$

证明要点

[联合典型引理证明] 独立采样意味着 $p(\tilde{x}^n, \tilde{y}^n) = p(\tilde{x}^n) \cdot p(\tilde{y}^n)$ 。

$$\begin{aligned}
 P((\tilde{x}^n, \tilde{y}^n) \in A_\epsilon^{(n)}) &= \sum_{(x^n, y^n) \in A_\epsilon^{(n)}} p(x^n) \cdot p(y^n) \\
 &\leq |A_\epsilon^{(n)}| \cdot \max_{x^n \in A} p(x^n) \cdot \max_{y^n \in A} p(y^n) \\
 &\leq 2^{n(H(X,Y)+\epsilon)} \cdot 2^{-n(H(X)-\epsilon)} \cdot 2^{-n(H(Y)-\epsilon)} \\
 &= 2^{-n(H(X)+H(Y)-H(X,Y)-3\epsilon)} \\
 &= 2^{-n(I(X;Y)-3\epsilon)}
 \end{aligned}$$

含义：两个独立生成的序列“偶然”看起来像联合分布采样（即落在联合典型集中）的概率，随 n 指数级衰减，衰减速率恰为互信息 $I(X;Y)$ 。

JTL 的关键对比（课件 p.9）：

- 联合采样 $(X^n, Y^n) \stackrel{\text{i.i.d.}}{\sim} P_{XY}$ ：落在联合典型集的概率 $\rightarrow 1$
- 独立采样 $\tilde{X}^n \perp\!\!\!\perp \tilde{Y}^n$ ：落在联合典型集的概率 $\leq 2^{-n(I-3\epsilon)} \rightarrow 0$ （指数快）

这构成了译码的基础：**正确的码字**（与 Y^n 联合采样）极大概率联合典型；**错误的码字**（与 Y^n 独立）极大概率不联合典型。

8.4 正向证明（若 $R < C$ ，则存在编码方案使 $P_e \rightarrow 0$ ）

总体策略：随机编码 + 联合典型译码。

8.4.1 Step 1: 香农的期望技巧

问题：好的编码方案未知——不同的 C_n 对应不同的 P_e ，但我们不知道哪个好。

香农的思路（课件 p.13）：期望是最小元素的上界。

$$\min_i f_i \leq \mathbb{E}[F] = \sum_i p_i f_i$$

如果能在某个随机编码方案集合上证明平均误差 $\rightarrow 0$ ，则至少存在一个具体的编码方案，其误差 $\leq$ 平均误差 $\rightarrow 0$ 。

关键优势：计算平均误差时，不需要知道编码方案的分布 $P(C_n)$ 的具体形式——期望运算自动抹平了分布细节。

8.4.2 Step 2: 随机码本构造

固定一个输入分布 P_X （先不指定是哪个，后面再取最优的）。

从典型集 $A_\epsilon^{(n)}(X)$ 中，独立、均匀地随机抽取 $M = 2^{nR}$ 个序列作为码字：

$$\text{码本: } x^n(1), x^n(2), \dots, x^n(M)$$

每个码字对应一个消息。码本总共有 $|\mathcal{X}|^{n \cdot M}$ 种可能——构成了随机编码方案的集合，每种码本等概率。

8.4.3 Step 3: 联合典型译码规则

接收到 y^n 后，在码本中搜索：

译码成功 ($\hat{u} = u$) $\iff$

- $(x^n(u), y^n) \in A_\epsilon^{(n)}(X, Y)$ (发送的码字与接收序列联合典型)
- 对所有 $k \neq u$: $(x^n(k), y^n) \notin A_\epsilon^{(n)}(X, Y)$ (其他码字都不联合典型)

译码错误 $\iff$

- $(x^n(u), y^n) \notin A_\epsilon^{(n)}(X, Y)$, 或
- 存在 $k \neq u$ 使 $(x^n(k), y^n) \in A_\epsilon^{(n)}(X, Y)$

即：译码器寻找唯一与 y^n 联合典型的码字。找到且唯一则成功，否则宣布失败。

8.4.4 Step 4: 误差概率分析 (Union Bound)

假设消息 U 均匀分布，由对称性只需分析 $U = 1$ 的情况 (所有消息地位等同)。

误差事件分解：

$$\begin{aligned} P_e^{(n)} &= P(\text{译码错误} \mid U = 1) \\ &= P\left((x^n(1), y^n) \notin A_\epsilon^{(n)} \text{ OR } \exists k \neq 1 : (x^n(k), y^n) \in A_\epsilon^{(n)}\right) \\ &\leq \underbrace{P((x^n(1), y^n) \notin A_\epsilon^{(n)})}_{\text{事件 } E_1: \text{正确码字不典型}} + \sum_{k=2}^M \underbrace{P((x^n(k), y^n) \in A_\epsilon^{(n)})}_{\text{事件 } E_2: \text{错误码字恰好典型}} \end{aligned}$$

事件 E_1 的控制 (AEP): $(X^n(1), Y^n)$ 是联合采样的 ($X^n(1) \stackrel{\text{i.i.d.}}{\sim} P_X$, Y^n 通过信道 $P_{Y|X}$ 由 $X^n(1)$ 产生), 故由 AEP 性质:

$$P((x^n(1), y^n) \notin A_\epsilon^{(n)}) \leq \epsilon \quad (n \text{ 足够大时})$$

事件 E_2 的控制 (联合典型引理): 对 $k \neq 1$, $x^n(k)$ 是独立于 $x^n(1)$ 、从而独立于 y^n 随机生成的。 $X^n(k) \stackrel{\text{i.i.d.}}{\sim} P_X$ 与 $Y^n \stackrel{\text{i.i.d.}}{\sim} P_Y$ 相互独立——这正是 JTL 的前提！因此:

$$P((x^n(k), y^n) \in A_\epsilon^{(n)}) \leq 2^{-n(I(X;Y)-3\epsilon)}$$

合成:

$$\begin{aligned} P_e^{(n)} &\leq \epsilon + (M - 1) \cdot 2^{-n(I(X;Y)-3\epsilon)} \\ &\leq \epsilon + M \cdot 2^{-n(I(X;Y)-3\epsilon)} \\ &= \epsilon + 2^{nR} \cdot 2^{-n(I(X;Y)-3\epsilon)} \quad (\because M = 2^{nR}) \\ &= \epsilon + 2^{-n(I(X;Y)-R-3\epsilon)} \end{aligned}$$

8.4.5 Step 5: 取极限与存在性

若 $R < I(X; Y) - 3\epsilon$, 则指数 $I(X; Y) - R - 3\epsilon > 0$, 当 $n \rightarrow \infty$ 时:

$$P_e^{(n)} \leq \epsilon + 2^{-n(\text{正数})} \rightarrow \epsilon$$

ϵ 可取任意小, 故 $P_e^{(n)} \rightarrow 0$ 。

以上 $P_e^{(n)}$ 是随机码本上的平均误差。由香农的期望技巧:

$$\mathbb{E}_{C_n}[P_e] \rightarrow 0 \implies \exists C_n^* \text{ 使 } P_e(C_n^*) \rightarrow 0$$

最后, 取 $P_X = P_X^*$ (容达分布, 即使 $I(X; Y) = C$ 的输入分布), 得:

任意 $R < C$ 均可达。

8.4.6 正向证明小结

1. 固定 P_X , 随机生成 $M = 2^{nR}$ 个码字
2. 联合典型译码: 找唯一与 y^n 联合典型的码字
3. Union Bound 拆误差: E_1 (AEP 控制) + E_2 (JTL 控制)
4. 得到 $P_e \leq \epsilon + 2^{-n(I-R-3\epsilon)} \rightarrow 0$ (若 $R < I$)
5. 取容达分布得 $R < C$; 平均误差 $\rightarrow 0$ 则存在好码

8.5 反向证明 (若 $R > C$, 则任何编码方案都有 $P_e > 0$)

策略: Fano 不等式 + 数据处理不等式 + DMC 性质。

反向证明要证明的是任何编码方案都无法超过 C , 因此不能对编码器的输出 X^n 或译码器的输入 Y^n 做 i.i.d. 假设——我们不知道、也不该假设编码器是如何工作的。唯一可以依赖的是信道本身的性质: 离散无记忆信道 (DMC)。

8.5.1 Step 1: Fano 不等式给出误差下界

消息 U 均匀分布 (不失一般性), $H(U) = \log M = nR$ 。考虑马尔可夫链 $U \rightarrow X^n \rightarrow Y^n \rightarrow \hat{U}$, Fano 不等式:

$$H(U | Y^n) \leq 1 + P_e \cdot \log M = 1 + P_e \cdot nR$$

将 $H(U | Y^n) = H(U) - I(U; Y^n) = nR - I(U; Y^n)$ 代入并整理:

$$P_e \geq 1 - \frac{I(U; Y^n)}{nR} - \frac{1}{nR}$$

8.5.2 Step 2: DPI 消除编码器

$U \rightarrow X^n \rightarrow Y^n$ 是马尔可夫链 (消息决定码字, 信道决定输出), 由 DPI:

$$I(U; Y^n) \leq I(X^n; Y^n)$$

8.5.3 Step 3: 用 DMC 放缩 $I(X^n; Y^n) \leq nC$

这是反向证明最关键的一步。展开 $I(X^n; Y^n) = H(Y^n) - H(Y^n | X^n)$:

- $H(Y^n | X^n)$ 的处理——可用 **DMC**: 信道无记忆性保证 $p(y^n | x^n) = \prod p(y_i | x_i)$, 因此 $H(Y^n | X^n) = \sum_{i=1}^n H(Y_i | X_i)$ 。这一步不需要 X_i 之间独立。
- $H(Y^n)$ 的处理——不可假设 Y_i 独立 (编码器可能使 X_i 相关, 进而 Y_i 也相关)。但联合熵有一个恒成立的上界: $H(Y^n) \leq \sum_{i=1}^n H(Y_i)$ 。

代入:

$$I(X^n; Y^n) = H(Y^n) - \sum_{i=1}^n H(Y_i | X_i) \leq \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i | X_i) = \sum_{i=1}^n I(X_i; Y_i) \leq n \cdot \max_{P_X} I(X; Y) = nC$$

注意: $H(Y^n) \leq \sum H(Y_i)$ 当 Y_i 不独立时是严格小于号——这是反向证明之所以能成功的关键: 不假设独立只让上界变松了 ($\leq$), 但方向正确, 不影响最终结论。

8.5.4 Step 4: 得出结论

将 $I(X^n; Y^n) \leq nC$ 和 DPI 的结果代入 Fano 下界:

$$P_e \geq 1 - \frac{nC}{nR} - \frac{1}{nR} = 1 - \frac{C}{R} - \frac{1}{nR}$$

当 $R > C$ 时, $1 - \frac{C}{R} > 0$ 。取 n 充分大使 $\frac{1}{nR}$ 任意小, 则 $P_e > 0$ 。即: 任何编码方案下, 传输错误概率都有正下界, 不可能任意小。

8.5.5 小结: 正向 vs 反向的假设差异

	正向 ($R < C$ 可达)	反向 ($R > C$ 不可达)
要证明什么	存在一个好的编码方案	任何编码方案都做不到
能否假设 X^n i.i.d.	能——在随机码本构造中自然成立	不能——编码器可以任意
能否假设 Y^n i.i.d.	能——DMC + X^n i.i.d. 保证了	不能—— X^n 不独立则 Y^n 也不独立
能用什么	AEP、联合典型引理	仅 DMC + $H(Y^n) \leq \sum H(Y_i)$

8.6 几何解释

输出空间视角 (课件 p.21-22):

- 输出端典型集总大小: $\approx 2^{nH(Y)}$ (所有可能的典型输出序列数)
- 每个码字在输出端形成一个“噪声球”: 大小为 $\approx 2^{nH(Y|X)}$
(给定发送码字 x^n , 信道输出的不确定性范围)
- 可区分的码字总数 $\leq$ 输出空间 / 噪声球大小:

$$2^{nR} \cdot 2^{nH(Y|X)} \leq 2^{nH(Y)} \implies R \leq H(Y) - H(Y|X) = I(X; Y) \leq C$$

- 当 $n \rightarrow \infty$ 时, 所有 DMC 都表现得像噪声打印机 (课件 p.23) ——
大数定理使得每个码字对应的输出分布集中在其条件典型集内

8.7 平均误差到最大误差 (Expurgation)

正向证明得到的是平均误差 $\rightarrow 0$ 。但实际通信中，我们关心的是每个消息的误差是否都小。

Expurgation (删减) 方法 (课件 p.24):

给定编码方案 C_n ，平均误差为：

$$P_e(C_n) = \frac{1}{M} \sum_{u=1}^M P_e(u)$$

将 M 个状态按 $P_e(u)$ 从大到小排列。去掉误差最大的一半状态 ($M/2$ 个)，剩余状态的最大误差 $\leq 2P_e(C_n)$ (因为最差的一半的误差均值 $\geq$ 剩下一半的均值)。

删减后的传输率：

$$R' = \frac{\log(M/2)}{n} = \frac{\log M - 1}{n} = R - \frac{1}{n} \xrightarrow{n \rightarrow \infty} R$$

结论：当 $n \rightarrow \infty$ 时，可以在不损失传输率的前提下，将平均误差的可达性转化为最大误差的可达性。即：存在编码方案使所有消息的误差都 $\rightarrow 0$ 。

9 信道容量计算

9.1 信道容量计算

$C = \max_{P_X} I(X; Y)$ ，目标函数 $I(X; Y)$ 关于 P_X 为凹函数，约束为凸集，一阶最优即全局最优。

KKT 条件：

$$\begin{aligned} \frac{\partial I}{\partial p_i} &= \lambda, & p_i > 0 \\ \frac{\partial I}{\partial p_i} &\leq \lambda, & p_i = 0 \end{aligned}$$

其中 $\frac{\partial I}{\partial p_i} = D_{\text{KL}}(p(Y|X=x_i) \| p(Y)) - 1$ 。

对称信道——必考

Gallager (1968) 定义：离散无记忆信道 $P_{Y|X}$ 的信道矩阵，按输出集划分成若干子矩阵后，每个子矩阵满足：

- 每一行都是其他行的排列
- 每一列都是其他列的排列

核心性质：对称信道的最优输入分布 = 均匀分布。

常见对称信道：二元对称信道 (BSC)、二元删除信道 (BEC)、噪声打印机。

9.1.1 对称信道的判断方法

方法 1：行列检查法（强对称/简单情形）：

若信道矩阵的每一行都是其他行的排列，且每一列也是其他列的排列，则为对称信道。

方法 2：Gallager 子矩阵法（广义情形）：

将输出符号分组，每组的列构成一个子矩阵。若每个子矩阵内行列均可互换排列，则为对称信道。

- 例： $P_{Y|X} = \begin{bmatrix} 0.7 & 0.2 & 0.1 \\ 0.1 & 0.2 & 0.7 \end{bmatrix}$ ，行可互换、列可分两组 $\{Y=0, Y=1\}$ 和 $\{Y=?\}$ ，前者是 2×2 行列可互换子矩阵。

方法 3：关键性质验证法：

若每行 $H(Y|X=x)$ 都相同（即每行的概率集合是同一集合的排列），且均匀输入下 $H(Y)$ 容易算——则该信道极有可能是对称信道。

9.1.2 对称信道容量计算

对于对称信道， $p(x) = 1/|\mathcal{X}|$ （均匀分布）时达到容量：

$$C = H(Y) \big|_{p(x) \text{ 均匀}} - H(Y|X = x_{\text{任意一行}})$$

其中 $H(Y|X=x)$ 取任意一行计算即可（各行熵相同）。

9.1.3 对称信道实例（附容量推导）

(1) 二元对称信道 (BSC)：翻转概率 f

$$P_{Y|X} = \begin{bmatrix} 1-f & f \\ f & 1-f \end{bmatrix}$$

行 $\{1-f, f\}$ 互为排列，列也互为排列——对称信道，最优输入 $p(0) = p(1) = \frac{1}{2}$ 。

容量推导：

$$C = H(Y) \big|_{\text{均匀}} - H(Y|X = x_{\text{任意一行}})$$

均匀输入下， $p_Y(0) = \frac{1}{2}(1-f) + \frac{1}{2}f = \frac{1}{2}$ ， $p_Y(1) = \frac{1}{2}$ ，故 $H(Y) = 1$ 。每行的条件熵 $H(Y|X=x) = H_2(f) = -f \log f - (1-f) \log(1-f)$ 。

$$\boxed{C = 1 - H_2(f)}$$

当 $f=0$ （无噪声）时 $C=1$ bit； $f=0.5$ （完全随机）时 $C=0$ 。

(2) 二元删除信道 (BEC)：删除概率 α

$$P_{Y|X} = \begin{bmatrix} 1-\alpha & \alpha & 0 \\ 0 & \alpha & 1-\alpha \end{bmatrix}$$

Gallager 分组: $\{Y = 0, Y = 1\}$ 为一组, $\{Y = ?\}$ 单独——对称信道, 最优输入均匀。

容量推导 (两种方法):

方法一 (对称信道公式): 均匀输入下, $p_Y(0) = \frac{1-\alpha}{2}$, $p_Y(1) = \frac{1-\alpha}{2}$, $p_Y(?) = \alpha$ 。 $H(Y) = H_2(\alpha) + (1-\alpha) \cdot 1$ (α 概率为 erasure + $1-\alpha$ 概率均匀分布在 $\{0, 1\}$)。 $H(Y|X = x) = H_2(\alpha)$ (每行都是 $\{1-\alpha, \alpha, 0\}$)。 $C = H(Y) - H(Y|X) = [H_2(\alpha) + (1-\alpha)] - H_2(\alpha) = 1-\alpha$ 。

方法二 (互信息直接计算——更直观): $I(X; Y) = H(X) - H(X|Y)$ 。 均匀输入下 $H(X) = 1$ 。 当 $Y = ?$ 时 $H(X|Y = ?) = 1$ (erasure 不提供任何信息); 当 $Y = 0$ 或 $Y = 1$ 时 $H(X|Y) = 0$ (完美确定 X)。 $H(X|Y) = \alpha \cdot 1 + (1-\alpha) \cdot 0 = \alpha$ 。

$$C = I(X; Y) = 1 - \alpha$$

BEC 的容量有直观解释: α 比例的信息被删除, 剩下 $1-\alpha$ 比例完美传输。

(3) 噪声打印机: 每个键 $1/2$ 正确, $1/4$ 偏左, $1/4$ 偏右

$$P_{Y|X} = \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & 0 & \cdots & 0 & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \end{bmatrix}$$

行循环置换, 列也循环置换——对称信道。容量:

$$C = \log |\mathcal{Y}| - H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{4}, 0, \dots, 0\right)$$

即 $\log |\mathcal{Y}|$ 减去每行条件熵。

9.1.4 非对称信道如何处理

若信道矩阵的行不互为排列 (即 $H(Y|X = x)$ 随 x 变化), 则不是对称信道。需用 KKT 条件 / Blahut-Arimoto 算法数值求解 C 和最优 P_X 。注意: 即使非对称, $I(X; Y)$ 关于 P_X 仍是凹函数, $\max_{P_X} I(X; Y)$ 仍是良定义的凸优化问题。

10 Hamming 码

考试范围

Hamming 码的编码 + 译码全流程必考。Viterbi 算法/HMM 不考。

10.1 核心思想: 数据流形

- 合理数据满足特定结构 (流形): $Hx = 0$
- 零空间编码: 在 $Hx = 0$ 的流形上编码 (码字 = 零空间中的向量)
- 错误检测: 接收 y , 计算校验子 $\eta = Hy$
 - $\eta = 0$: y 在零空间上, 判定正确
 - $\eta \neq 0$: y 不在零空间上, 发生错误
- 纠错: 将错误数据投影回最近流形点 (翻转出错位)

10.2 GF(2) 算术与错误表示

- GF(2) 加法 = XOR (异或), 常记为 $\oplus$
- 标准基向量 e_k : 第 k 位为 1、其余为 0 的列向量
- 第 k 位出现错误: $y = x + e_k$ (对应位翻转)
- 第 i 位和第 j 位同时出错: $y = x + e_i + e_j$
- 关键性质: $He_k = H$ 的第 k 列 $\triangleq \eta_k$ (校验子直接指向错误位置!)

10.3 汉明矩阵 H 的结构

- $H_{m \times n} \in \text{GF}(2)^{m \times n}$, 满秩
- 列向量 = 位置编码: H 的各列互不相同且非零
- $\oplus$ 校验子 $\eta = Hy = He_k = H(:, k)$, 由此定位错误位
- 码长关系: $n = 2^m - 1$ (以 Hamming(7,4) 为例, $m = 3, n = 7$)
- 零空间维数: $n - \text{rank}(H) = n - m = 2^m - m - 1$ (可编码数据 bit 数)
- 码字总个数: 2^{n-m}

10.4 编码流程 (Hamming(7,4) 实例)

以经典 Hamming(7,4) 为例 ($m = 3, n = 7$):

$$H = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix}$$

- 校验位位置: $2^0, 2^1, 2^2$ 即第 1, 2, 4 位 (x_1, x_2, x_4)
- 数据位位置: 其余位置 3, 5, 6, 7 (x_3, x_5, x_6, x_7)
- 零空间方程 $Hx = 0$:

$$\begin{cases} x_4 + x_5 + x_6 + x_7 = 0 \\ x_2 + x_3 + x_6 + x_7 = 0 \\ x_1 + x_3 + x_5 + x_7 = 0 \end{cases}$$

- 编码步骤:

1. 将 4 bit 数据放入数据位 x_3, x_5, x_6, x_7

$$2. \text{ 通过零空间方程解出校验位: } \begin{cases} x_4 = x_5 + x_6 + x_7 \\ x_2 = x_3 + x_6 + x_7 \\ x_1 = x_3 + x_5 + x_7 \end{cases} \quad (\text{均为 GF}(2) \text{ 加法} = \text{XOR})$$

3. 组合得到 7 bit 码字 ($x_1, x_2, x_3, x_4, x_5, x_6, x_7$)

- 本质: 分组奇偶校验——每个校验位负责 H 中对应行非零元所在的数据位

10.5 译码流程

1. 接收 y (7 bit), 计算校验子 $\eta = Hy$ (GF(2) 矩阵乘法, 逐行 XOR)
2. 判断:
 - $\eta = (0, 0, 0)^T$: 无错误, 直接取数据位输出
 - $\eta = \eta_k \neq 0$: 第 k 位出错 (η 等于 H 的第 k 列), 翻转 y_k , 纠正后取数据位输出
3. 若两位出错: $\eta = \eta_i + \eta_j \neq 0$ (可检测, 但无法确定是哪两位)
4. 纠错能力: 可检测一位或两位错误, 可纠正一位错误

10.6 Hamming 距离

定义 10.1 (Hamming 距离). $D_H(x^n, y^n) = \sum_{k=1}^n x_k \oplus y_k$ (不同位的个数)

性质 10.2. (1) 非负性: $D_H(x, y) \geq 0$

(2) 对称性: $D_H(x, y) = D_H(y, x)$

(3) 三角不等式: $D_H(x, y) + D_H(y, z) \geq D_H(x, z)$

几何意义: 实现两序列相等所需的最少 0-1 bit 翻转次数。

最小距离与纠错能力

码字空间中任意两个不同码字的最小 Hamming 距离 $d_{\min}$ 决定纠错能力:

$$\text{可纠正 } t \text{ 位错} \iff d_{\min} \geq 2t + 1$$

Hamming(7,4): $d_{\min} = 3$, 故可纠 1 位错 ($2 \times 1 + 1 = 3$)。

$d_{\min} = 3$ 的证明: H 各列互不相同且非零, 任意非零码字至少需 3 个不同的列相加才能得零向量。故码字空间 (除全零元外) 各向量非零元个数 ≥ 3 。不同码字 $x \neq y$, $z = x + y$ 也是码字 (零空间是线性子空间), 故 $D_H(x, y) = \|z\|_0 \geq 3$ 。

(附) Viterbi 算法——不考

不考内容

不考内容。Viterbi 算法、HMM、卷积码均不在此次考试范围内。仅需了解: Viterbi 算法用于卷积码的最优译码, 核心为动态规划/最短路径搜索。

11 连续情况与高斯信道

11.1 微分熵

定义 11.1 (微分熵). $h(X) = -\int f_X(x) \log f_X(x) dx$

微分熵可以为负数。

典型值: $X \sim U(a, b)$: $h(X) = \log(b - a)$ ($b - a < 1$ 时为负)。

变量替换: $h(AX + c) = h(X) + \log|\det A|$ 。

连续 KL 散度和互信息仍然非负:

$$D_{\text{KL}}(f\|g) = \int f \log \frac{f}{g} dx \geq 0$$

$$I(X; Y) = D_{\text{KL}}(f_{X,Y} \| f_X f_Y) = h(X) - h(X|Y) \geq 0$$

11.2 高斯分布——最大熵分布

定理 11.2 (高斯分布微分熵). $X^n \sim \mathcal{N}(\mu, \Sigma)$:

$$h(X^n) = \frac{n}{2} \log(2\pi e) + \frac{1}{2} \log |\Sigma|$$

定理 11.3 (最大熵定理). 给定协方差 Σ 的所有分布中, 高斯分布熵最大:

$$h(X^n) \leq \frac{n}{2} \log(2\pi e) + \frac{1}{2} \log |\Sigma|$$

证明要点

$0 \leq D_{\text{KL}}(f\|g) = -h(X^n) - \int f(\mathbf{x}) \log g(\mathbf{x}) d\mathbf{x}$, 计算 $\int f \log g = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{n}{2 \ln 2}$, 移项得证。

11.3 高斯信道

信道模型: $Y_i = X_i + W_i$, $W_i \sim \mathcal{N}(0, \sigma^2)$, 功率约束: $\frac{1}{n} \sum X_i^2 \leq P$ 。

定理 11.4 (高斯信道容量).

$$C = \frac{1}{2} \log \left(1 + \frac{P}{\sigma^2} \right)$$

证明要点

$I(X; Y) = h(Y) - h(Y|X) = h(Y) - h(W)$ 。 $\mathbb{E}[Y^2] = \mathbb{E}[X^2] + \mathbb{E}[W^2] \leq P + \sigma^2$ 。最大熵分布: $Y \sim \mathcal{N}(0, P + \sigma^2)$, $h(Y) \leq \frac{1}{2} \log(2\pi e(P + \sigma^2))$ 。 $h(W) = \frac{1}{2} \log(2\pi e \sigma^2)$, 代入得 $C = \frac{1}{2} \log(1 + P/\sigma^2)$ 。

11.4 并行高斯信道——水填充 (Water-Filling)

水填充算法

$$\max_{\{P_i\}} \sum_{i=1}^n \frac{1}{2} \log \left(1 + \frac{P_i}{N_i} \right), \quad s.t. \sum P_i = P, P_i \geq 0$$

最优解: $P_i^* = (\mu - N_i)^+ = \max(\mu - N_i, 0)$ 。 μ 由 $\sum P_i^* = P$ 确定。

KKT 推导: $-\frac{1}{2} \frac{1}{N_i + P_i} + \lambda - \nu_i = 0$, $\nu_i P_i = 0$ 。若 $P_i > 0$, $P_i = \frac{1}{2\lambda} - N_i$; 若 $P_i = 0$, $\frac{1}{2\lambda} \leq N_i$ 。令 $\mu = 1/(2\lambda)$ 即得。

12 率失真理论——有损压缩

12.1 问题表述

有损压缩: N 个符号压缩为 m bit, 压缩率 $R = m/N$, 失真 $\mathbb{E}[d(V, \hat{V})] \leq D$ 。

对偶问题:

$$\min R \text{ s.t. } \mathbb{E}[d] \leq D \iff \min \mathbb{E}[d] \text{ s.t. } R \leq R_0$$

12.2 常用失真函数

- Hamming 失真: $d(x, y) = \mathbf{1}[x \neq y]$ (二进制数据)
- 平方误差: $d(x, y) = (x - y)^2$ (图像/连续数据)
- Itakura-Saito 距离 (语音信号)

12.3 率失真函数

定义 12.1 (信息率失真函数).

$$R_I(D) = \min_{p(\hat{V}|V): \mathbb{E}[d(V, \hat{V})] \leq D} I(V; \hat{V})$$

定理 12.2 (率失真定理). $R(D) = R_I(D)$ 。若 $R > R_I(D)$ 则 (R, D) 可达; 若 $R < R_I(D)$ 则不可达。

12.4 率失真函数性质

$R(D)$ 的性质

- (1) 凸函数: $R(\lambda D_1 + (1 - \lambda)D_2) \leq \lambda R(D_1) + (1 - \lambda)R(D_2)$
- (2) $R(0) = H(V)$ (无损压缩时等于源熵)
- (3) 存在 D_{max} 使得 $R(D_{max}) = 0$, $D \geq D_{max}$ 时 $R(D) = 0$
- (4) 单调递减: $D_1 < D_2 \Rightarrow R(D_1) \geq R(D_2)$

证明要点

[凸性证明 (Time-sharing)] 对长为 N 的序列, λN 部分用失真 D_1 编码 (压缩率 $R(D_1)$), $(1 - \lambda)N$ 部分用失真 D_2 编码 (压缩率 $R(D_2)$)。整体: $R = \lambda R(D_1) + (1 - \lambda)R(D_2)$, $\mathbb{E}[d] = \lambda D_1 + (1 - \lambda)D_2$ 。该失真下的最优压缩率 $R(\lambda D_1 + (1 - \lambda)D_2) \leq$ 此方案的压缩率。

12.5 高斯信源的率失真函数

定理 12.3 (高斯信源 RD). $V \sim \mathcal{N}(0, \sigma^2)$, 平方误差失真:

$$R(D) = \begin{cases} \frac{1}{2} \log \frac{\sigma^2}{D}, & 0 \leq D \leq \sigma^2 \\ 0, & D > \sigma^2 \end{cases}$$

证明要点

$I(V; \hat{V}) = h(V) - h(V|\hat{V}) \geq h(V) - h(V - \hat{V}) \geq \frac{1}{2} \log(2\pi e \sigma^2) - \frac{1}{2} \log(2\pi e D) = \frac{1}{2} \log(\sigma^2/D)$ 。等号条件: $V - \hat{V} \sim \mathcal{N}(0, D)$ 且与 $\hat{V}$ 独立, $\hat{V} \sim \mathcal{N}(0, \sigma^2 - D)$ 。

13 率失真与信道编码的假设对比

可达性证明中的独立同假设

	正向 (可达)	反向 (不可达)
信道编码	需假设 X^n, Y^n i.i.d.	不假设 i.i.d. (仅 DMC)
率失真	需假设 $V^N, \hat{V}^N$ i.i.d.	不假设 $\hat{V}^N$ i.i.d.

14 信源信道分离

14.1 问题背景

我们已经分别建立了两个理论:

- 信源编码 (数据压缩): V^N (N 个 i.i.d. 符号) $\rightarrow$ 压缩为 m bit。

率失真定理: 若 $R \geq R_I(D)$, 则存在压缩方案使失真 $\leq D$ 。最小 bit 数: $m \geq N \cdot R_I(D)$ 。

- 信道编码 (可靠传输): m bit 消息 $\rightarrow n$ 次信道使用 $\rightarrow$ 解码。

噪声信道编码定理: 若 $R \leq C_I$, 则存在编码方案使 $P_e \rightarrow 0$ 。最大可传 bit 数: $m \leq n \cdot C_I$ 。

自然的问题: 能不能把两个模块串起来——先压缩、再传——构成一个完整的通信系统? 如果能, 这个“分离”方案是不是最优的? 有没有“联合编码”方案可以做得更好?

14.2 分离方案 (Separation Scheme)

发送端:	V^N	$\xrightarrow{\text{信源编码器}}$	$m \text{ bit}$	$\xrightarrow{\text{信道编码器}}$	X^n	$\xrightarrow{\text{信道 } P_{Y X}}$	Y^n
接收端:	Y^n	$\xrightarrow{\text{信道译码器}}$	$m \text{ bit}$	$\xrightarrow{\text{信源译码器}}$	$\hat{V}^N$		

分离方案就是把两个独立的编码器级联: 中间共享一个 m bit 的消息。

分离方案的可行性条件

分离方案存在 $\iff$ 能找到一个 m 同时满足两边的要求：

$$\underbrace{N \cdot R_I(D)}_{\text{压缩所需最小 bit}} \leq \log_2 M = m \leq \underbrace{n \cdot C_I}_{\text{信道可传最大 bit}}$$

即：

$$\boxed{N \cdot R_I(D) \leq n \cdot C_I} \quad \text{或等价地} \quad \boxed{\frac{N}{n} \leq \frac{C_I}{R_I(D)}}$$

解读：信源序列长 N ，信道可用 n 次。

- 信源端至少需要 $N \cdot R_I(D)$ bit 来描述数据（失真 $\leq D$ ）；
- 信道端最多能可靠传输 $n \cdot C_I$ bit。
- 只要需求 $\leq$ 供给，分离方案就可行。

14.3 联合编码方案（Joint Coding Scheme）

联合方案不显式拆成“先压缩、再编码”两步——编码器直接把 V^N 映射为 X^n ，译码器直接把 Y^n 映射为 $\hat{V}^N$ 。

$$\begin{array}{l} \text{发送端: } V^N \xrightarrow{\text{联合编码器}} X^n \\ \text{接收端: } Y^n \xrightarrow{\text{联合译码器}} \hat{V}^N \end{array}$$

核心问题：联合方案能不能超越分离方案？比如 $N \cdot R_I(D) > n \cdot C_I$ 时，分离方案不可行——联合方案有希望吗？

14.4 联合方案的必然约束（反向证明）

整个通信链路构成马尔可夫链： $V^N \rightarrow X^n \rightarrow Y^n \rightarrow \hat{V}^N$ 。

对联合方案应用两个定理的反向部分：

- 率失真定理反向（需要 V^N i.i.d.）： $I(V^N; \hat{V}^N) \geq \sum_{i=1}^N I(V_i; \hat{V}_i) \geq N \cdot R_I(D)$
 - DPI（数据处理不等式）： $V^N \rightarrow X^n \rightarrow Y^n \rightarrow \hat{V}^N$ 是马尔可夫链，故 $I(V^N; \hat{V}^N) \leq I(X^n; Y^n)$
 - 信道编码定理反向（仅需 DMC）： $I(X^n; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq n \cdot C_I$
- 三者串联得到任何联合方案都必然满足的不等式链：

联合编码的必要条件

$$\boxed{N \cdot R_I(D) \leq I(V^N; \hat{V}^N) \leq I(X^n; Y^n) \leq n \cdot C_I}$$

因此，任何可靠通信方案都必须满足：

$$\frac{N}{n} \leq \frac{C_I}{R_I(D)}$$

这意味着：即使是最聪明的联合编码方案，也无法突破这个不等式。

若 $N \cdot R_I(D) > n \cdot C_I$ ，不仅分离方案不可行——任何方案都不可行。

14.5 分离定理 (Separation Theorem)

联合方案的必要条件和分离方案的可行性条件完全相同：

$$N \cdot R_I(D) \leq n \cdot C_I$$

定理 14.1 (信源信道分离定理). 若 $N \cdot R_I(D) \leq n \cdot C_I$ ，则存在分离编码方案（信源编码 + 信道编码独立设计）实现可靠通信。

若 $N \cdot R_I(D) > n \cdot C_I$ ，则任何编码方案（包括联合编码）都无法实现可靠通信。

分离方案不损失任何传输效率——在所有可达方案中就是最优的。

分离定理的现实意义

- 模块化设计：信源编码和信道编码可以分开设计、分开优化，互不干扰
- 分工协作：做压缩的人只管压缩率，做通信的人只管信道容量，拼起来就是最优
- 理论基础：整个通信系统的理论模型——信源 $\rightarrow$ 信源编码 $\rightarrow$ 信道编码 $\rightarrow$ 信道 $\rightarrow$ 信道译码 $\rightarrow$ 信源译码——正是建立在这个定理之上

15 变分自编码器 (VAE) 与率失真理论

15.1 率失真问题的三种形式

课件 p.11 总结了率失真 trade-off 的三种等价表述，这也是理解 VAE 的入口：

(1) 率失真问题 (Shannon): $\min \text{rate}, \quad \text{s.t. } \text{distortion} \leq D$

(2) 失真率问题 (对偶): $\min \text{distortion}, \quad \text{s.t. } \text{rate} \leq R$

(3) 无约束形式 (工程实用): $\min (\text{Rate} + \beta \cdot \text{Distortion})$

前两种是理论分析用的（强约束），第三种把约束写成罚项——这正是 VAE 训练的形式。

15.2 VAE 的基本结构

编码器 $q_\phi(z|x)$: 把数据 x 映射到潜变量 z (概率化编码)。

解码器 $p_\theta(\hat{x}|z)$: 把潜变量 z 重建为 $\hat{x}$ 。

训练目标 (Loss):

$$\mathcal{L} = \underbrace{\mathbb{E}_{q_\phi(z|x)} [-\log p_\theta(\hat{x}|z)]}_{\text{重建误差 (Distortion)}} + \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{KL 正则项 (Rate)}}$$

通常取先验 $p(z) = \mathcal{N}(0, I)$ ，编码器输出 $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \sigma_\phi^2(x))$ 。

15.3 ELBO 的来源

对数似然 $\log p(x)$ 不可直接优化（需要积分 z ）。引入编码器 $q_\phi(z|x)$ ：

$$\begin{aligned}\log p(x) &= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p_\theta(x, z)}{q_\phi(z|x)} \right] + D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x)) \\ &\geq \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p_\theta(x, z)}{q_\phi(z|x)} \right] \triangleq \text{ELBO}\end{aligned}$$

展开 ELBO：

$$\text{ELBO} = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

最大化 ELBO = 最小化负 ELBO = 重建误差 + KL 正则。

15.4 从信息论角度看 VAE

15.4.1 正则项 = 编码率 (Rate)

将 KL 正则项对数据分布求期望并展开（课件 p.15）：

$$\begin{aligned}\mathbb{E}_{x \sim p_{\text{data}}} [D_{\text{KL}}(q_\phi(z|x) \| p(z))] &= \mathbb{E}_{x, z} \left[\log \frac{q_\phi(z|x)}{q_\phi(z)} \cdot \frac{q_\phi(z)}{p(z)} \right] \\ &= I_{q_\phi}(X; Z) + D_{\text{KL}}(q_\phi(z) \| p(z)) \\ &\geq I_{q_\phi}(X; Z)\end{aligned}$$

最小化 KL 正则项 $\iff$ 最小化互信息 $I(X; Z)$ 。

而 $I(X; Z)$ 正是率失真理论中要最小化的量——编码率 (Rate) 的下界。

15.4.2 重建误差 = 失真度 (Distortion)

在高斯解码器 $p_\theta(\hat{x}|z) = \mathcal{N}(\hat{x}, \sigma^2 I)$ 下：

$$-\log p_\theta(x|z) = \frac{1}{2\sigma^2} \|x - \text{Decoder}(z)\|^2 + \text{const}$$

这恰好是平方误差失真 $d(x, \hat{x}) = \|x - \hat{x}\|^2$ 的形式。

15.4.3 VAE 就是在逼近率失真极限

$$\mathcal{L}_{\text{VAE}} \approx \underbrace{\mathbb{E}[\text{distortion}]}_{\text{失真 } D} + \underbrace{I(X; Z)}_{\text{编码率 } R}$$

训练 VAE 本质上是在解： $\min(\text{Rate} + \text{Distortion})$ ——率失真问题的第三种形式。

当训练收敛时，编码器 q_ϕ 找到了给定失真水平下使互信息最小的“测试信道”，解码器 p_θ 实现了该压缩率下的最优重建。这就是为什么说 VAE 在逼近香农的率失真函数 $R(D)$ 。

15.4.4 β -VAE

$$\mathcal{L}_\beta = \text{Distortion} + \beta \cdot \text{Rate}$$

β 控制 rate-distortion 的权衡: - $\beta > 1$: 更强的压缩 (更小的 $I(X; Z)$), 更大的失真 - $\beta < 1$: 更好的重建质量, 更多信息保留在 Z 中

这在信息论上完全对应率失真 trade-off 曲线上的不同工作点。

15.5 考试要点

- VAE 的 loss = 重建误差 + KL 正则 $\approx \text{Distortion} + \text{Rate}$
- KL 正则项 $\geq I(X; Z)$, 最小化它就是在压缩互信息
- VAE 训练本质是在逼近香农率失真理论极限
- β -VAE 的 β 控制 rate-distortion 权衡
- 不考 VAE 的具体架构细节和训练 trick, 考的是它和信息论的联系

16 核心公式速查

表 1: 考试核心公式速查

名称	公式
基础度量与不等式	
熵	$H(X) = -\sum_x p(x) \log p(x)$
条件熵	$H(X Y) = \sum_y p(y) H(X Y=y)$
联合熵链式	$H(X, Y) = H(X) + H(Y X)$
互信息	$I(X; Y) = H(X) - H(X Y) = D_{\text{KL}}(p_{XY} \ p_X p_Y)$
KL 散度	$D_{\text{KL}}(p \ q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \geq 0$
交叉熵	$\text{CE}(p \ q) = H(p) + D_{\text{KL}}(p \ q)$
Jensen (凸)	$\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$
Log-sum	$\sum a_i \log \frac{a_i}{b_i} \geq (\sum a_i) \log \frac{\sum a_i}{\sum b_i}$

(续表)	
名称	公式
Kraft	$\sum D^{-l(x)} \leq 1$ (前缀码充要条件)
最优码长	$l^*(x) = -\log_D p(x)$
Fano	$P_e \geq \frac{H(X Y)-1}{H(X)} \geq \frac{H(X Y)-1}{\log \mathcal{X} }$
DPI	$X \rightarrow Y \rightarrow Z \Rightarrow I(X; Y) \geq I(X; Z)$
信道与编码	
信道容量	$C = \max_{P_X} I(X; Y)$
高斯信道容量	$C = \frac{1}{2} \log \left(1 + \frac{P}{\sigma^2}\right)$
水填充	$P_i^* = (\mu - N_i)^+$
联合典型引理	$P \leq 2^{-n(I(X; Y) - 3\epsilon)}$ (独立采样)
率失真函数	$R(D) = \min_{p(\hat{V} V): \mathbb{E}d \leq D} I(V; \hat{V})$
高斯率失真	$R(D) = \frac{1}{2} \log \frac{\sigma^2}{D}$
渐进理论与其它	
熵率 (平稳)	$H' = \lim_{n \rightarrow \infty} \frac{1}{n} H(X^n) = \lim H(X_n X^{n-1})$
马尔可夫熵率	$H(X_0 X_{-1}) = \sum_i u_i \sum_j P_{ij} \log \frac{1}{P_{ij}}$
Huffman	$\min \sum p_x l_x, \text{ s.t. } \sum 2^{-l_x} \leq 1, l_x \in \mathbb{Z}^+$
AEP 概率界	$2^{-n(H+\epsilon)} \leq p(x^n) \leq 2^{-n(H-\epsilon)}$
AEP 大小界	$(1-\epsilon)2^{n(H-\epsilon)} \leq A_\epsilon^{(n)} \leq 2^{n(H+\epsilon)}$

17 关键证明思路汇总

1. KL 散度非负

- 法一：Log-sum 不等式，代入 $a_x = p(x), b_x = q(x)$
- 法二：Jensen 不等式，利用 $-\log x$ 凸性

2. 均匀分布熵最大： $H(p) = \log |\mathcal{X}| - D_{\text{KL}}(p||u) \leq \log |\mathcal{X}|$

3. 熵的凹性

- 法一：Log-sum 不等式
- 法二：Jensen + $x \log x$ 凸
- 法三： $H(p) = \log |\mathcal{X}| - D_{\text{KL}}(p||u) + \text{KL 凸性}$
- 法四：条件熵 $H(X|Y) \leq H(X) + \text{构造混合分布}$

4. Kraft 不等式

- 充分性：二分分布构造前缀树（补充缺失概率）
- 必要性：完全二叉树的叶子计数

5. Huffman 最优性：递归归约——融合/扩展保持最优性

6. Fano 不等式： $H(E, X|\hat{X})$ 的两种链式展开

7. DPI：互信息链式法则 $I(X; Y, Z) = I(X; Z) + I(X; Y|Z) = I(X; Y) + I(X; Z|Y)$

8. 联合典型引理： $p(x^n)p(y^n)$ 对典型集求和 + AEP 界

9. 信道编码正向（20 分大题，5 步）：

- 香农期望技巧： $\min_i f_i \leq \mathbb{E}[F]$ ——若随机码本平均误差 $\rightarrow 0$ ，则存在一个好码
- 随机码本构造：固定 P_X ，从 $A_\epsilon^{(n)}(X)$ 中独立均匀抽取 $M = 2^{nR}$ 个码字
- 联合典型译码：接收 y^n 后，找唯一与 y^n 联合典型的码字 $\hat{u}$ ；若无或多于一个则译码错误
- Union Bound 误差分析：

$$\begin{aligned}
 P_e &\leq \underbrace{P((x^n(1), y^n) \notin A_\epsilon^{(n)})}_{E_1: \text{AEP} \leq \epsilon} + \sum_{k=2}^M \underbrace{P((x^n(k), y^n) \in A_\epsilon^{(n)})}_{E_2: \text{JTL} \leq 2^{-n(I-3\epsilon)}} \\
 &\leq \epsilon + M \cdot 2^{-n(I-3\epsilon)} = \epsilon + 2^{-n(I-R-3\epsilon)} \xrightarrow{n \rightarrow \infty} 0 \quad (\text{若 } R < I)
 \end{aligned}$$

- 存在性：取容达分布 P_X^* 使 $I(X; Y) = C$ ，得任意 $R < C$ 可达

10. 信道编码反向（4 步）：

- Fano： $H(U|Y^n) \leq 1 + P_e \cdot nR \Rightarrow P_e \geq 1 - \frac{I(U; Y^n)}{nR} - \frac{1}{nR}$
- DPI： $U \rightarrow X^n \rightarrow Y^n$ 是马尔可夫链， $I(U; Y^n) \leq I(X^n; Y^n)$

(c) **DMC 仅:** $I(X^n; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq nC$ (不假设 i.i.d.)

(d) **结论:** $P_e \geq 1 - \frac{C}{R} - \frac{1}{nR} > 0$ (若 $R > C$, n 足够大)

11. **高斯信道容量 (计算, 不考推导):** $C = \frac{1}{2} \log(1 + \frac{P}{\sigma^2})$ 。给定功率 P 和噪声方差 σ^2 直接代公式。并行信道用水填充: $P_i^* = (\mu - N_i)^+$, μ 由 $\sum P_i^* = P$ 确定。

12. **率失真凸性:** Time-sharing argument: 对序列分两段, 各用不同的失真-率配置

13. **几何解释——噪声球与失真球 (重点)**

信息论两大极限的几何统一

	信道编码 (可靠传输)	率失真 (有损压缩)
基本问题	噪声信道中最大传多少 bit?	允许失真 D 下最少需多少 bit?
极限量	信道容量 $C = \max I(X; Y)$	率失真函数 $R(D) = \min I(V; \hat{V})$
几何图像	噪声球	失真球
球的大小	$\approx 2^{nH(Y X)}$ (每个码字)	$\approx 2^{nH(\hat{V} V)}$ (每个码字)
空间总大小	$\approx 2^{nH(Y)}$ (输出端)	$\approx 2^{nH(V)}$ (数据空间)
可区分/覆盖数	$\leq 2^{nI(X; Y)}$	$\geq 2^{nI(V; \hat{V})}$
极限条件	$2^{nR} \cdot 2^{nH(Y X)} \leq 2^{nH(Y)}$	$2^{nR} \cdot 2^{nH(\hat{V} V)} \geq 2^{nH(V)}$
结论	$R \leq I(X; Y) \leq C$	$R \geq I(V; \hat{V}) \geq R(D)$

信道编码的噪声球: 每个发送码字 x^n 经过噪声信道后, 输出 y^n 分布在以 x^n 为中心、大小为 $2^{nH(Y|X)}$ 的”噪声球”内。 2^{nR} 个球要互不重叠地塞进大小为 $2^{nH(Y)}$ 的输出空间, 所以 $2^{nR} \cdot 2^{nH(Y|X)} \leq 2^{nH(Y)} \Rightarrow R \leq I(X; Y)$ 。 $n \rightarrow \infty$ 时, 大数定理使所有 DMC 都表现为噪声打印机——每个码字的输出分布恰好是一个”噪声球”。

率失真的失真球: 数据空间中, 每个”代表码字” $\hat{v}^n$ 覆盖一个大小为 $2^{nH(\hat{V}|V)}$ 的”失真球”——球内的原始数据点都可以用该码字替代 (失真 $\leq D$)。 2^{nR} 个失真球要覆盖整个数据空间 $2^{nH(V)}$, 所以 $2^{nR} \cdot 2^{nH(\hat{V}|V)} \geq 2^{nH(V)} \Rightarrow R \geq I(V; \hat{V})$ 。

对偶关系: 信道编码是”球的打包”——球不能重叠 (可区分), R 受限于空间/球; 率失真”球的覆盖”——球必须覆盖全空间, R 需要至少空间/球。一个最大化 I (上限), 一个最小化 I (下限)。