

信息论

不太适合速记的速记纸

吴钦鸿

目录

一、 信息的统计度量	1
二、 信息度量的界与凹凸性	3
三、 渐进均分性	7
四、 Markov 信源	10
五、 Markov 信源(二)	13
六、 符号编码	15
七、 信道容量	19
八、 连续的情形	25
8.1 高斯分布	25
8.2 高斯信道	27
九、 Hamming 码	29
十、 率失真	31

一、信息的统计度量

熵

$$H(X) = \mathbb{E}[-\log p(X)]$$

条件熵

$$\begin{aligned} H(X|Y) &= \mathbb{E}_{X,Y}[-\log p(X|Y)] \\ &= \mathbb{E}_Y[\mathbb{E}_{X|Y}[-\log p(X|Y)]] \\ &= \mathbb{E}_Y[H(X|Y=y)] \end{aligned}$$

互信息

$$\begin{aligned} I(X;Y) &= H(X) - H(X|Y) \\ &= \sum_{X,Y} p(x,y) \log \frac{p(x|y)}{p(x)} \\ &= \sum_{X,Y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \\ &= \mathbb{E}_{X,Y} \left[\log \frac{p(x,y)}{p(x)p(y)} \right] \end{aligned}$$

联合熵

$$\begin{aligned} H(X,Y) &= \mathbb{E}_{X,Y}[-\log p(X,Y)] \\ &= \sum_{X,Y} p(x,y) \log \frac{1}{p(x)p(y|x)} \\ &= \sum_{X,Y} p(x,y) \log \frac{1}{p(x)} + \sum_{X,Y} p(x,y) \log \frac{1}{p(y|x)} \\ &= H(X) + H(Y|X) \end{aligned}$$

注解 1.1 (链式法则)

$$H(X,Y) = H(X) + H(Y|X)$$

$$H(X,Y|Z) = H(X|Z) + H(Y|X,Z)$$

推广:

$$H(X_1^n) = \sum_{i=1}^n H(X_i|X_1^{i-1})$$

相对熵 (KL 散度)


$$\begin{aligned} D_{KL}(p\|q) &= \mathbb{E}_{X \sim p(X)} \left[\log \frac{p(X)}{q(X)} \right] \\ &= \text{CE}(p, q) - H(p) \end{aligned}$$

注解 1.2

$$I(X;Y) = D_{KL}(p(X,Y)\|p(X)p(Y))$$

交叉熵

$$\text{CE}(p, q) = \mathbb{E}_{X \sim p}[-\log q(X)]$$



二、信息度量的界与凹凸性

定理 2.1 (Jesen 不等式)

对凸函数 $f(x)$,

$$E(f(X)) \geq f(E(X))$$

当且仅当 $X \equiv E(X)$ 时取等。

注解 2.2

$-\log x$, $x \log x$ 都是凸函数, 所以

$$\mathbb{E}[-\log X] \geq -\log(\mathbb{E}[X]) \quad (2.1)$$

$$\mathbb{E}[X \log(X)] \geq \mathbb{E}(X) \log(\mathbb{E}(X)) \quad (2.2)$$

性质 2.3 (KL 散度非负性)

$$D_{\text{KL}} = \mathbb{E}_{X \sim p} \left[-\log \frac{p(X)}{q(X)} \right]$$

$$\stackrel{(*)}{\geq} -\log \left(\mathbb{E}_{X \sim p} \left[\frac{q(X)}{p(X)} \right] \right) = -\log \left(\sum_X p(X) \frac{q(X)}{p(X)} \right) = -\log \left(\sum_X q(X) \right) = -\log 1 = 0$$

第(*)步用到了式 (2.1).

当且仅当 $p = q$ 时取等。

推论 2.3.1 (互信息非负性)

$$I(X; Y) = D_{\text{KL}}(p(X, Y) \| p(X)p(Y)) \geq 0$$

当且仅当 $X \perp Y$ 时取等。

推论 2.3.2 (条件熵不大于原熵)

$$H(X) - H(X|Y) = I(X; Y) \geq 0$$

当且仅当 $X \perp Y$ 时取等。

推论 2.3.3 (均匀分布时熵最大)

假设 X 是离散随机变量, $\mathcal{X}$ 上的均匀分布 $u(x) = \frac{1}{|\mathcal{X}|}$

$$\begin{aligned} H(X) &= \mathbb{E}[-\log p(X)] = \mathbb{E}_{X \sim p} \left[-\log u(X) \frac{p(X)}{u(X)} \right] \\ &= -\log u(X) - D_{\text{KL}}(p \| u) \\ &= \log |\mathcal{X}| - D_{\text{KL}}(p \| u) \end{aligned}$$

$$\leq \log |\mathcal{X}| \quad (p = u \text{ 时取等})$$

当且仅当 X 服从均匀分布时取等.

定理 2.4 (对数和不等式)

$$\sum a_i \log \frac{a_i}{b_i} \geq \left(\sum a_i \right) \log \left(\frac{\sum a_i}{\sum b_i} \right)$$

当且仅当 $\frac{a_i}{b_i}$ 为定值时取等.

性质 2.5 (KL 散度的凸性)

D_{KL} 关于 (p, q) 是凸的. 即

$$\lambda D_{\text{KL}}(p_1 \| q_1) + (1 - \lambda) D_{\text{KL}}(p_2 \| q_2) \geq D_{\text{KL}}(\lambda p_1 + (1 - \lambda) p_2 \| \lambda q_1 + (1 - \lambda) q_2)$$

证明.

$$\begin{aligned} & \lambda D_{\text{KL}}(p_1 \| q_1) + (1 - \lambda) D_{\text{KL}}(p_2 \| q_2) \\ &= \sum_X \lambda p_1(x) \log \frac{\lambda p_1(x)}{\lambda q_1(x)} + (1 - \lambda) p_2(x) \log \frac{\lambda p_2(x)}{\lambda q_2(x)} \\ &\stackrel{(*)}{\geq} \sum_X (\lambda p_1(x) + (1 - \lambda) p_2(x)) \log \frac{\lambda p_1(x) + (1 - \lambda) p_2(x)}{\lambda q_1(x) + (1 - \lambda) q_2(x)} \\ &= D_{\text{KL}}(\lambda p_1 + (1 - \lambda) p_2 \| \lambda q_1 + (1 - \lambda) q_2) \end{aligned}$$

第 (*) 步用到了定理 2.4 (对数和不等式)

□

性质 2.6 (熵的凹性)

$H(X)$ 关于 X 的分布具有凹性, 即

$$\lambda H(p_1) + (1 - \lambda) H(p_2) \leq H(\lambda p_1 + (1 - \lambda) p_2)$$

证明.

$$\begin{aligned} \text{左边} &= - \sum_X \lambda p_1(x) \log p_1(x) + (1 - \lambda) p_2(x) \log p_2(x) \\ &= - \sum_X \lambda p_1(x) \log \frac{\lambda p_1(x)}{\lambda} + (1 - \lambda) p_2(x) \log \frac{(1 - \lambda) p_2(x)}{1 - \lambda} \\ &\stackrel{(*)}{\leq} - \sum_X (\lambda p_1(x) + (1 - \lambda) p_2(x)) \log \frac{\lambda p_1(x) + (1 - \lambda) p_2(x)}{\lambda + (1 - \lambda)} \\ &= H(\lambda p_1 + (1 - \lambda) p_2) \end{aligned}$$

第 (*) 步用到了定理 2.4 (对数和不等式)

□

性质 2.7 (互信息的凹凸性)

$p(Y|X)$ 确定时, $I(X; Y)$ 是 $p(X)$ 的凹函数.

$p(X)$ 确定时, $I(X; Y)$ 是 $p(Y|X)$ 的凸函数.

证明. $I(X; Y)$ 可以展开成如下形式:

$$\begin{aligned} I(X; Y) &= \sum_{XY} p(x)p(y|x) \log \frac{p(y|x)}{p(y)} \\ &= \sum_{XY} p(x)p(y|x) \log \frac{p(y|x)}{\sum_X p(x)p(y|x)} \end{aligned} \quad (2.3)$$

命题 1: $p(Y|X)$ 确定时, $I(X; Y)$ 是 $p(X)$ 的凹函数. 接着式 (2.3) 可得:

$$I(X; Y) = \sum_{XY} p(x)p(y|x) \log p(y|x) - \sum_{XY} p(x)p(y|x) \log \left(\sum_X p(x)p(y|x) \right)$$

$p(Y|X)$ 确定时, 上式第一项关于 $p(X)$ 线性, 下面考虑第二项.

令 $G(p(X)) = \sum_{XY} p(x)p(y|x) \log \left(\sum_X p(x)p(y|x) \right)$, 对任意 $0 < \lambda < 1$

$$\begin{aligned} &\lambda G(p_1(X)) + (1 - \lambda)G(p_2(X)) \\ &= \lambda \sum_{XY} p_1(x)p(y|x) \log \left(\sum_X p_1(x)p(y|x) \right) \\ &\quad + (1 - \lambda) \sum_{XY} p_2(x)p(y|x) \log \left(\sum_X p_2(x)p(y|x) \right) \\ &= \sum_Y \left(\sum_X \lambda p_1(x)p(y|x) \log \left(\sum_X p_1(x)p(y|x) \right) \right. \\ &\quad \left. + \sum_X (1 - \lambda) p_2(x)p(y|x) \log \left(\sum_X p_2(x)p(y|x) \right) \right) \\ &= \sum_Y \left(\sum_X \lambda p_1(x)p(y|x) \log \frac{\sum_X \lambda p_1(x)p(y|x)}{\lambda} \right. \\ &\quad \left. + \sum_X (1 - \lambda) p_2(x)p(y|x) \log \frac{\sum_X (1 - \lambda) p_2(x)p(y|x)}{1 - \lambda} \right) \\ &\geq \sum_Y \sum_X \lambda p_1(x)p(y|x) + (1 - \lambda) p_2(x)p(y|x) \log \frac{\sum_X \lambda p_1(x)p(y|x) + (1 - \lambda) p_2(x)p(y|x)}{\lambda + 1 - \lambda} \\ &= \sum_Y \left(\sum_X (\lambda p_1(x) + (1 - \lambda) p_2(x)) p(y|x) \right) \log \left(\sum_X (\lambda p_1(x) + (1 - \lambda) p_2(x)) p(y|x) \right) \\ &= G(\lambda p_1(X) + (1 - \lambda) p_2(X)) \end{aligned}$$

不等式那一步利用了定理 2.4 (对数和不等式).

所以 $G(p(x))$ 关于 $p(X)$ 是凸的. 从而 $I(X; Y) = \sum_{XY} p(x)p(y|x) \log p(y|x) - G(p(X))$ 关于 $P(X)$ 是凹函数.

命题 2: $p(X)$ 确定时, $I(X; Y)$ 是 $p(Y|X)$ 的凸函数.

利用式 (2.3) 展开 $\lambda I_{p_1(Y|X)}(X; Y) + (1 - \lambda)I_{p_2(Y|X)}(X; Y)$:

$$\begin{aligned}
 & \lambda I_{p_1(Y|X)}(X; Y) + (1 - \lambda)I_{p_2(Y|X)}(X; Y) \\
 &= \sum_{XY} p(x) \left[\lambda p_1(y|x) \log \frac{p_1(y|x)}{\sum_X p(x)p_1(y|x)} + (1 - \lambda)p_2(y|x) \log \frac{p_2(y|x)}{\sum_X p(x)p_2(y|x)} \right] \\
 &= \sum_{XY} p(x) \left[\lambda p_1(y|x) \log \frac{\lambda p_1(y|x)}{\sum_X p(x)\lambda p_1(y|x)} + (1 - \lambda)p_2(y|x) \log \frac{(1 - \lambda)p_2(y|x)}{\sum_X p(x)(1 - \lambda)p_2(y|x)} \right] \\
 &\geq \sum_{XY} p(x) \left[\lambda p_1(y|x) + (1 - \lambda)p_2(y|x) \right] \log \frac{\lambda p_1(y|x) + (1 - \lambda)p_2(y|x)}{\sum_X p(x)(\lambda p_1(y|x) + (1 - \lambda)p_2(y|x))} \\
 &= I_{\lambda p_1(Y|X) + (1 - \lambda)p_2(Y|X)}(X; Y)
 \end{aligned}$$

不等式那一步利用了定理 2.4 (对数和不等式).

所以, $p(X)$ 确定时, $I(X; Y)$ 是 $p(Y|X)$ 的凸函数.

□

注解 2.8

在命题 1 的证明中, $-G(P(X)) = H(Y)$, 所以当 $P(Y|X)$ 确定时, $H(Y)$ 关于 $P(X)$ 是凹的.

三、渐进均分性

独立同分布的 n 个符号 U 组成符号序列 U^n . n 充分大时, U^n 的典型集高概率地出现, 而且典型集中元素概率对数地接近, 这就是渐进均分性.

引理 3.1 (弱大数定理)

$\bar{X} = \sum_{i=1}^n X_i$, $\text{Var}[X] = \sigma^2$, 那么

$$\begin{aligned} \forall \varepsilon > 0 \\ P(|\bar{X} - \mathbb{E}[X]| \leq \varepsilon) &> 1 - \frac{\sigma^2}{n\varepsilon^2} \\ \exists N, \forall n > N \\ P(|\bar{X} - \mathbb{E}[X]| \leq \varepsilon) &> 1 - \frac{\sigma^2}{n\varepsilon^2} > 1 - \varepsilon \end{aligned} \quad (3.4)$$

定义 3.2 (ε -典型集)

随机变量序列 U^n 的 ε -典型集定义为

$$A_\varepsilon^{(n)} = \left\{ u^n \mid \left| \frac{1}{n} \log \frac{1}{p(u^n)} - H(U) \right| < \varepsilon \right\}$$

性质 3.3 (高概率)

$$\forall \varepsilon > 0, P(U^n \in A_\varepsilon^{(n)}) \xrightarrow{n \rightarrow \infty} 1$$

利用引理 3.1 (弱大数定理)立刻可以得到.

性质 3.4 (概率上下界)

$$2^{-n(H(U)+\varepsilon)} \leq p(u^n) \leq 2^{-n(H(U)-\varepsilon)}$$

从定义立刻得到.

性质 3.5 (数量上下界)

$$(1 - \varepsilon)2^{n(H(U)-\varepsilon)} \leq |A_\varepsilon^{(n)}| \leq 2^{n(H(U)+\varepsilon)}$$

其中,下界是在 n 充分大时的下界,利用了式 (3.4).

性质 3.6 (占比)

$$\frac{|A_\varepsilon^{(n)}|}{|U^n|} \approx \frac{2^{nH(U)}}{|U|^n} = 2^{-n(\log|U| - H(U))} = 2^{-n(D_{\text{KL}}(p\|u))}$$

当 $p \neq u$, n 充分大时, $\frac{|A_\varepsilon^{(n)}|}{|U^n|} \rightarrow 0$

命题 3.7 (高概率集的下界)

$B^{(n)} \subseteq U^n, \delta > 0, |B^{(n)}| \leq 2^{n(H(U)-\delta)}$, 那么

$$P(U^n \in B^{(n)}) \xrightarrow{n \rightarrow \infty} 0$$

证明. 取 $\varepsilon < \delta$ 的典型集 $A_\varepsilon^{(n)}$

$$P(U^n \in B^{(n)}) = P(U^n \in (B^{(n)} \cap A_\varepsilon^{(n)})) + \underbrace{P(U^n \in (B^{(n)} - A_\varepsilon^{(n)}))}_{\leq P(U^n \notin A_\varepsilon^{(n)}) \rightarrow 0}$$

$$\begin{aligned} P(U^n \in (B^{(n)} \cap A_\varepsilon^{(n)})) &= \sum_{u^n \in B^{(n)} \cap A_\varepsilon^{(n)}} p(u^n) \\ &\leq |B^{(n)}| 2^{-n(H(U)-\varepsilon)} \\ &\leq 2^{n(H(U)-\delta)} 2^{-n(H(U)-\varepsilon)} \\ &= 2^{-n(\delta-\varepsilon)} \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

□

推论 3.7.1

任何满足性质 3.3 (高概率) 的集合 $B^{(n)}$, 下界还可以比性质 3.5 更紧:

$$|B^{(n)}| \geq 2^{nH(U)}$$

定理 3.8 (信源定长编码定理)

对于 i.i.d 信源 U^n , 记 S_δ 为编码误差在 δ 内 ($P(U^n \in S_\delta) \geq 1 - \delta$) 的最小集合, 对于任意 $\varepsilon > 0$ 和 $0 < \delta < 1$, 存在正整数 n_0 , 当 $n > n_0$ 时, 编码长度 $\log|S_\delta|$ 满足:

$$\left| \frac{1}{n} \log|S_\delta| - H(U) \right| < \varepsilon$$

证明. 先证明存在 n_0 使得 $\frac{1}{n} \log|S_\delta| < H(U) + \varepsilon$:

只编码典型集 $A_\varepsilon^{(n)}$ 中的元素.

对于任意 $\varepsilon > 0$, 选取 n_0 使得 $1 - \frac{\sigma^2}{n_0 \varepsilon^2} \geq 1 - \delta$

$n > n_0$ 时, $A_\varepsilon^{(n)}$ 是编码误差在 δ 内的集合:

$$P(U^n \in A_\varepsilon^{(n)}) \geq 1 - \frac{\sigma^2}{n_0 \varepsilon^2} \geq 1 - \delta$$

编码误差在 δ 内的最小集合 S_δ 应该不比 $A_\varepsilon^{(n)}$ 大:

$$\frac{1}{n} \log|S_\delta| \leq \frac{1}{n} \log|A_\varepsilon^{(n)}| \leq H(U) + \varepsilon$$

再证明存在 n_0 使得 $\frac{1}{n} \log|S_\delta| > H(U) - \varepsilon$:

如果存在 ε , 使得对于任意 n_0 总存在 $n > n_0$, $\frac{1}{n} \log|S_\delta| \leq H(U) - \varepsilon$ 即

$$|S_\delta| \leq 2^{(n(H(U)-\varepsilon))}$$

取 $n_0 \rightarrow \infty$, 那么 n 也 $\rightarrow \infty$, 根据命题 3.7 (高概率集的下界)

$$P(U^n \in S_\delta) \xrightarrow{n \rightarrow \infty} 0$$

与 $P(U^n \in S_\delta) \geq 1 - \delta > 0$ 矛盾.

□

定义 3.9 (熵率)

对于未必 i.i.d 的符号序列 X^n , 熵率 $H(\mathcal{X})$ 定义为

$$H(\mathcal{X}) = \lim_{n \rightarrow \infty} H(X^n)$$

定义 3.10 (平稳信源)

联合分布时不变的信源称为平稳信源, 即满足

$$\forall k, n, p(X_1^n) = p(X_k^{n+k-1})$$

性质 3.11 (熵下标可平移)

$$H(X_1^n) = H(X_k^{n+k-1}) = H(X_{-n}^{-1})$$

$$H(X_n | X_1^{n-1}) = H(X_{k+n} | X_k^{k+n-1}) = H(X_0 | X_{-(n-1)}^{-1})$$

性质 3.12 (平稳信源的熵率存在)

平稳信源的熵率 $H(\mathcal{X})$ 存在, 且

$$H(\mathcal{X}) = \lim_{n \rightarrow \infty} H(X_n | X_1^{n-1}) = \lim_{n \rightarrow \infty} H(X_0 | X_{-(n-1)}^{-1})$$

定理 3.13 (SMB 定理)

对于平稳遍历信源 X^n , 有

$$\lim_{n \rightarrow \infty} \frac{1}{n} \log \frac{1}{p(x^n)} = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \log \frac{1}{p(x_i | x_1^{i-1})} = \text{熵率 } H(\mathcal{X})$$

从而定理 3.8 (信源定长编码定理) 对平稳遍历信源依然成立.

四、Markov 信源

定义 4.1 (Markov 过程)

如果

$$p(X_i | X_{i-1}) = p(X_i | X_{i-1}, X_{i-2}, \dots)$$

称随机过程为 **Markov 过程**, 也称为 **Markov 链**.

一般研究的 Markov 过程是时不变的, 类似上节所说的平稳信源.

定义 4.2 (转移矩阵)

Markov 过程的**转移矩阵** $P_{i,j}$, 第 i 行第 j 列是从状态 i 转移到状态 j 的概率, 即

$$P_{ij} = p(X_0 = S_j | X_{-1} = S_i)$$

从而

$$p_{X_0} = p_{X_{-1}} P$$

性质 4.3 (多步转移的转移矩阵)

如果单步转移矩阵为 P , 那么转移 n 步的转移矩阵为 P^n . 即

$$p(x_n = S_j | x_0 = S_i) = P_{ij}^n$$

结合 C-K 方程证明.

定义 4.4 (平稳分布)

如果

$$u_X = u_X P$$

称分布 u_X 是平稳分布

注解 4.5 (细致平衡条件)

如果分布 u 满足细致平衡条件, 即

$$\forall i, j \quad u_i P_{ij} = u_j P_{ji}$$

(直观地看, 就是对于每对状态 i, j , 从 i 转移到 j 的概率等于从 j 转移到 i 的概率)

那么 u 是平稳分布.

性质 4.6 (Markov 过程的熵率)

初始态为平稳分布 u 的 Markov 过程是平稳过程.

根据性质 3.12 (平稳信源的熵率存在) 可得:

$$\begin{aligned}
H(\mathcal{X}) &= \lim_{n \rightarrow \infty} H(X_0 | X_{-(n-1)}^{-1}) \\
&= \lim_{n \rightarrow \infty} H(X_0 | X_{-1}) \\
&= H(X_0 | X_{-1}) \\
&= - \sum_i u_i \sum_j P_{ij} \log P_{ij}
\end{aligned}$$

定义 4.7 (不可约)

如果

$$\forall i, j, \exists k, P_{ij}^k > 0$$

称该 Markov 过程**不可约**.

直观来看, 每个状态总可以转移到另一状态.

定义 4.8 (非周期)

$\gcd\{k : P(X_k = s | X_0 = s) > 0\}$ 称为状态 s 的**周期**. 如果周期 > 1 , 那么称状态 s 是**周期的**, 否则称为**非周期的**.

如果所有状态时周期的, 称该 Markov 过程是周期的. 否则称为非周期的, 即如果

$$\exists s, \gcd\{k : P(X_k = s | X_0 = s) > 0\} = 1$$

称该 Markov 过程**非周期**.

直观来看, 该状态 s 的所有环长度互质. 结合裴蜀定理, 充分多步之后, 再走任意步都有可能走到状态 s .

注解 4.9

不可约 Markov 过程, 各状态周期相等. 所以检查是否非周期只需要检查一个状态.

定理 4.10 (遍历性)

有限状态的 Markov 链(转移矩阵为 P), 如果不可约且非周期, 那么存在唯一平稳分布. 且该平稳分布等于极限分布

$$\pi_j = \lim_{n \rightarrow \infty} p(X_n = j | X_0 = i) = \lim_{n \rightarrow \infty} P_{ij}^n > 0$$

此时称该 Markov 链是**遍历的**.

直观来看, 从任意状态出发, 该 Markov 链都会收敛到该唯一的平稳分布, 且各状态概率 > 0 , 任意状态经过充分多步之后, 总会到达. 这就是就是遍历性的直觉含义.

证明. 下面给出笔者的证明思路, 中间步骤交给读者完成.

引理 4.11 (Perron–Frobenius 定理)

如果方阵 $A > 0$, 那么

- A 有唯一最大模的特征值
- 该特征值几何重数为 1, 且有一个对应的正特征向量

1. 从不可约和非周期出发, 证明

$$\exists N, \forall m > N, \forall i, j, P_{ij}^m > 0$$

(提示: 结合定义 4.8 (非周期)的“直观来看”句.)

2. 证明对于一个转移矩阵, 若存在特征向量, 那么最大模特征值必为 1. (提示: 对特征向量各分量求和)
3. 取一个 $m > N$, 那么 $P^m, P^{m+1}, P^{m(m+1)} > 0$. 根据引理 4.11 和第 2 步, 证明三个矩阵都含有唯一各分量全正的平稳分布, 分别记为 $u^{(m)}, u^{(m+1)}, u^{(m(m+1))}$
4. 证明 $u^{(m)} = u^{(m+1)} = u^{(m(m+1))}$, 此分布记为 u_X (提示: P^m 的特征向量也是 P^{km} 的特征向量)
5. 证明 u_X 是转移矩阵 P 对应的唯一平稳分布.
6. 证明 u_X 是极限分布, 即 $(u_X)_j = \lim_{n \rightarrow \infty} P_{ij}^n$ (提示: 利用 $u_X = \lim_{n \rightarrow \infty} u_0 P_{ij}^n$, 选择合适的 u_0 并比较两侧同一分量.) $\square$

定义 4.12 (遍历变换和遍历过程)

对于状态空间 Ω , 概率测度 P , 称一个变换 $T : \Omega \rightarrow \Omega$ 是**遍历的**, 如果

$$X = T(X), X \subseteq \Omega \text{ 当且仅当 } P(X) = 0 \text{ 或 } P(X) = 1$$

由遍历变换 T 组成的过程 $X_i = T^i(X_0)$, 称为**遍历过程**.

显然, 遍历的 Markov 链, 如果从平稳状态开始, 或者经过充分多步之后收敛到平稳状态, 那么每一步表示的变换是遍历变换. 这给出了遍历的 Markov 链可用于遍历定理的依据.

定理 4.13 (遍历定理)

设平稳遍历过程 $\{X_i\}$ 的变换为 T (即 $X_i = T^i(X_0)$), 那么对于任意函数 f :

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n f(T^i(X)) = \mathbb{E}[f(X)]$$

五、Markov 信源(二)

定义 5.1 (Markov 链)

Markov 链的另一个等价定义是:如果 $X \perp Y \mid Z$, 称随机变量 X, Y, Z 构成 Markov 链(记为 $X \rightarrow Y \rightarrow Z$)

定理 5.2 (数据处理不等式)

如果 $X \rightarrow Y \rightarrow Z$, 那么

$$I(X; Z) \leq I(X; Y)$$

定义 5.3 (充分统计量)

在 $\theta \rightarrow X \rightarrow T(X)$ 中, 如果

$$\theta \rightarrow T(X) \rightarrow X$$

称统计量 $T(X)$ 是充分统计量.

性质 5.4

- $I(T(X); X) = I(T(X); \theta)$ (从数据处理不等式立刻得到)
- $f(x|T(x) = t, \theta)$ 与 θ 无关(结合 Markov 链的定义)
- $T(X)$ 是充分统计量 $\iff f(x; \theta)$ 可写为 $h(x)g(T(x); \theta)$

定义 5.5 (指数族分布)

如果

$$f(x; \theta) = h(x) \exp(\eta(\theta)^T \tau(x) - A(\theta))$$

称 $f(x; \theta)$ 为指数族分布.

性质 5.6

- 单次实验时, $\tau(x)$ 是充分统计量.
- 多次实验时,

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n h(x_i) \exp\left(\eta(\theta)^T \left(\sum_{i=1}^n \tau(x_i)\right) - nA(\theta)\right)$$

$\sum_{i=1}^n \tau(x_i)$ 是充分统计量

定理 5.7 (Fano 不等式)

如果 $X \rightarrow Y \rightarrow \hat{X}$, 那么错误率 $P_e \triangleq P(X \neq \hat{X})$ 满足

$$H(X|Y) \leq 1 + P_e H(X)$$

当然可以进一步变成

$$\begin{aligned} P_e &\geq \frac{H(X|Y) - 1}{H(X)} \\ &= \frac{H(X) - I(X;Y) - 1}{H(X)} \\ &== 1 - \frac{I(X;Y) + 1}{H(X)} \end{aligned}$$

从中可见, $H(X)$ 不变时, $H(X|Y)$ 越大, 错误率下界越高; $I(X;Y)$ 越大, 错误率下界越低, 这很符合直觉.

六、符号编码

概念: 前缀码、即时码 (前缀码与即时码的等价性)、非奇异码、唯一可译码, 略过.

定义 6.1 (二分分布)

分布 $p(x) = 2^{-n_x}$, 称为二分分布.

性质 6.2

- 概率最小的元素一定有偶数个.
- 二分分布可构造一个前缀码
选两个概率最小的元素合并, 并分别在这两个元素的码字前添加 0 和 1. 合并完之后, 仍然是二分分布, 递归操作.

设符号为随机变量 X , 符号集为 $\mathcal{X}$, x 对应码字长为 $l(x)$, 采用二进制编码. 下述各定理都采用这些记号.

定理 6.3 (Kraft 定理)

存在给定长度 $\{l(x)\}$ 的前缀码的充分必要条件是

$$\sum_{x \in \mathcal{X}} 2^{-l(x)} \leq 1$$

证明. 充分性:

补充剩余概率 $1 - \sum_{x \in \mathcal{X}} 2^{-l(x)} = \sum_i 2^{-i}$, 形成一个二分分布, 在该二分分布构造的前缀码中只考虑 $\mathcal{X}$ 的元素.

必要性:

将前缀码对应的二叉树扩展称为满二叉树, 每个符号 x 对应节点为根的子树有 $2^{l_{\max} - l(x)}$ 个叶子, 那么

$$\sum_{x \in \mathcal{X}} 2^{l_{\max} - l(x)} \leq \text{总叶子数 } 2^{l_{\max}}$$

所以

$$\sum_{x \in \mathcal{X}} 2^{-l(x)} \leq 1$$

□

定理 6.4 (McMillan 不等式)

码字长为 $\{l(x)\}$ 的唯一可译码满足

$$\sum_{x \in \mathcal{X}} 2^{-l(x)} \leq 1$$

证明. 记符号总数 $m = |\mathcal{X}|$, 符号总码长 $S = \sum_{i=1}^m 2^{-l_i}$. 长度为 N 的符号序列, 所有可能的序列码长之和为

$$\begin{aligned}
 S^N &= \sum_{i_1=1}^m \sum (i_2=1)^m \cdots \sum (i_N=N)^m 2^{-\sum_{j=1}^N l_{i_j}} \\
 &= \sum_{l=Nl_{\min}}^{Nl_{\max}} a_l 2^{-l} \text{ (合并同类项)} \\
 &\leq \sum_{l=Nl_{\min}}^{Nl_{\max}} 2^l 2^{-l} \text{ (唯一可译码中, 码长为 } l \text{ 的符号序列至多 } 2^l \text{ 个)} \\
 &= N(l_{\max} - l_{\min})
 \end{aligned}$$

从而

$$S \leq (N(l_{\max} - l_{\min}))^{\frac{1}{N}}$$

所以 $S \leq \lim_{N \rightarrow \infty} (N(l_{\max} - l_{\min}))^{\frac{1}{N}} = 1$

□

注解 6.5 (前缀码在唯一可译码的最优性)

结合定理 6.3, 符号编码中, 任何唯一可译码, 都能构造出码字长对应的前缀码. 所以, 在求解最优符号编码时, 只需考虑前缀码.

定理 6.6 (码长下界)

符号 X 的期望码长 $\geq H(X)$.

证明. 求解最优期望码长的问题表述为

$$\begin{aligned}
 \min L &= \sum_{x \in \mathcal{X}} p(x) l(x) \\
 s.t. & \sum_{x \in \mathcal{X}} 2^{-l(x)} \leq 1
 \end{aligned}$$

令 $z = \sum_{x \in \mathcal{X}} 2^{-l(x)} \leq 1$, 构造概率分布 $q(x) = \frac{2^{-l(x)}}{z}$. 那么

$$l(x) = -\log q(x) - \log z$$

$$\begin{aligned}
 L &= \sum_{x \in \mathcal{X}} p(x) l(x) \\
 &= \sum_{x \in \mathcal{X}} -p(x) \log q(x) - p(x) \log z \\
 &= \sum_{x \in \mathcal{X}} -p(x) \log q(x) - \log z \\
 &\geq \text{CE}(p, q) \text{ (当且仅当 } z = 1 \text{ 即 Kraft 不等式取等时取等)} \\
 &\geq H(X) \text{ (当且仅当 } p = q \text{ 时取等)}
 \end{aligned}$$

□

注解 6.7

用近似分布 q 来编码真实分布 p 的符号, 最优期望码长是 $CE(p, q) = D_{KL}(p, q) + H(p)$. $D_{KL}(p, q)$ 衡量的是用近似分布的额外编码开销.

定理 6.8 (变长编码定理)

符号 X , 存在前缀码, 使得其平均编码码长 L 满足

$$H(X) \leq L < H(X) + 1$$

证明. 取 $l(x) = \lceil -\log p(x) \rceil$ 即可. 这种码字长的码称**香浓码**. □

性质 6.9 (最优前缀码的性质)

存在这样的最优前缀码, 满足

1. $\forall j, k$, 如果 $p_j > p_k$, 那么 $l_j \leq l_k$
2. 最长的两个码字长度相等
3. 最长的两个码字仅在最后一位有区别, 对应概率最小的两个符号

定理 6.10 (Huffman 编码的最优性)

在符号编码中, Huffman 编码的期望码长是最优的.

证明. 将分布

$$\mathbf{p} = (p_1, p_2, \dots, p_m) (p_1 \leq p_2 \leq \dots \leq p_m)$$

的两个最小概率符号融合, 得到

$$\mathbf{p}' = (p_1, p_2, \dots, p_{m-1} + p_{m+1})$$

要证明 Huffman 编码的最优性, 只需证明 $\mathbf{p}$ 的最优前缀码可由 $\mathbf{p}'$ 的最优前缀码扩展¹得到即可.

扩展 将 $\mathbf{p}'$ 的最优前缀码 (期望码长为 $L^*(\mathbf{p}') = \sum_{i=1}^m p_i l_i^*$), 扩展得到 $\mathbf{p}$ 的码, 其期望码长

$$\begin{aligned} L(\mathbf{p}) &= \sum_{i=1}^{m-2} p_i l_i^* + p_{m-1} (l_{m-1}^* + 1) + p_m (l_m^* + 1) \\ &= \sum_{i=1}^m p_i l_i^* + p_{m-1} + p_m \\ &= L^*(\mathbf{p}') + p_{m-1} + p_m \end{aligned} \tag{6.5}$$

合并 用 $\mathbf{p}$ 的满足性质 6.9 的最优前缀码 (期望码长为 $L^*(\mathbf{p}) = \sum_{i=1}^m p_i l_i^*$), 合并两个概率最小符号的码字², 得到 $\mathbf{p}'$ 的码, 其期望码长

¹扩展: 将 $\mathbf{p}'$ 中 $p_{m-1} + p_{m+1}$ 对应码字末尾分别添上 0 和 1 作为 $\mathbf{p}$ 中 p_{m-1} 和 p_{m+1} 的对应码字将

²合并: 这两个码字都去掉最后一位即相同

$$\begin{aligned}
L(\mathbf{p}') &= \sum_{i=1}^{m-2} p_i l_i^* + p_{m-1}(l_{m-1}^* - 1) + p_m(l_m^* - 1) \\
&= \sum_{i=1}^m p_i l_i^* - p_{m-1} - p_m \\
&= L^*(\mathbf{p}) - p_{m-1} - p_m
\end{aligned} \tag{6.6}$$

将式 (6.5) 和式 (6.6) 相加, 得到

$$(L(\mathbf{p}) - L^*(\mathbf{p})) + (L(\mathbf{p}') - L^*(\mathbf{p}')) = 0$$

考虑到 $L^*(\mathbf{p})$ 和 $L^*(\mathbf{p}')$ 的最优性, 可得

$$L(\mathbf{p}) = L^*(\mathbf{p}) \qquad L(\mathbf{p}') = L^*(\mathbf{p}')$$

这就说明 $\mathbf{p}'$ 扩展得到的码 (期望码长 $L(\mathbf{p})$), 也是 $\mathbf{p}$ 的最优码 (期望码长 $L^*(\mathbf{p})$), 从而求解 $\mathbf{p}$ 的最优码, 只需求解 $\mathbf{p}'$ 的最优码, 这正是 Huffman 编码的过程. $\square$

注解 6.11

- Huffman 编码的平均码长 $\leq$ 香浓码的平均码长
- Huffman 编码与一套 Yes/No 问题等价.

七、信道容量

概念: 通信模型、信道矩阵($p_{ij} = p_{Y|X}(Y = j | X = i)$)、离散无记忆信道、信道编码、传输率、可达传输率

定义 7.1 (信道容量)

信道 $P(Y|X)$ 的信道容量 C^I 定义为

$$C^I \triangleq \max_{P_X} I(X; Y)$$

信道容量的计算

$$C^I = \max_{P_X} I(X; Y)$$

$$x.t. \sum_x p(x) = 1$$

$$p(x) \geq 0, \forall x \in \mathcal{X}$$

 $\Rightarrow$

$$C^I = -\min_{P_X} -I(X; Y)$$

$$x.t. \sum_x p(x) = 1$$

$$-p(x) \leq 0, \forall x \in \mathcal{X}$$

(凸优化问题标准形式)

拉格朗日函数:

$$L(p, \lambda, \{\mu_i\}) = -I(X; Y) + \lambda \left(\sum_i p_i - 1 \right) - \sum_i \mu_i p_i$$

KKT 条件:

$$\frac{\partial L(p, \lambda, \{\mu_i\})}{\partial p_i} = \frac{\partial I(X; Y)}{\partial p_i} - \lambda + \mu_i = 0$$

$$\mu_i \geq 0$$

$$\mu_i p_i = 0$$

$$\sum_i p_i = 1$$

 $\Rightarrow$

$$\begin{cases} \frac{\partial I(X; Y)}{\partial p_i} = \lambda & \text{and } p_i > 0 \\ \frac{\partial I(X; Y)}{\partial p_i} \leq \lambda & \text{and } p_i = 0 \end{cases}$$

$$\sum_i p_i = 1$$

导数计算

$$\frac{\partial I(X; Y)}{\partial p_i} = D_{KL}(p(y|X = x_i) \| p(y)) - 1$$

定义 7.2 (弱对称信道)


如果信道矩阵每一行是其他行的置换, 每一列元素和 $\sum_x p(y|x)$ 相等, 那么称该信道是弱对称的.

弱对称信道的信道容容易求出, 设 $\mathbf{r}$ 为转移矩阵的一行, 则有

$$\begin{aligned} I(X; Y) &= H(Y) - H(Y|X) \\ &= H(Y) - H(\mathbf{r}) \\ &\leq \log |\mathcal{Y}| - H(\mathbf{r}) \end{aligned}$$

当且仅当 Y 为均匀分布时取得等号. 而且, $p(x) = \frac{1}{\log|\mathcal{X}|}$ 可以让 Y 达到均匀分布, 这是因为

$$p(y) = \sum_{x \in \mathcal{X}} p(y|x)p(x) = \frac{1}{\log|\mathcal{X}|} \sum p(y|x) = c \frac{1}{|\mathcal{X}|} = \frac{1}{|\mathcal{Y}|}$$



定理 7.3 (噪声信道编码定理)

- 正: 如果

$$R < \max_{P_X} I(X; Y)$$

则存在编码方案, 使得 **传输误差** 无限趋近于零

- 反: 如果

$$R > \max_{P_X} I(X; Y)$$

则 **传输误差** 必大于零

证明.

定义 7.4 (联合典型集)

分布 $P(X, Y)$ 的联合典型集 $A_\varepsilon^{(n)}(X, Y)$ 定义为

$$A_\varepsilon^{(n)}(X, Y) \triangleq \left\{ (x^n, y^n) \mid \begin{aligned} & \left| \frac{1}{n} \log \frac{1}{p(x^n)} - H(X) \right| \leq \varepsilon, & \swarrow x^n \text{ 是 } p_X \text{ 的典型序列} \\ & \left| \frac{1}{n} \log \frac{1}{p(y^n)} - H(Y) \right| \leq \varepsilon, & \swarrow y^n \text{ 是 } p_Y \text{ 的典型序列} \\ & \left| \frac{1}{n} \log \frac{1}{p(x^n, y^n)} - H(X, Y) \right| \leq \varepsilon \end{aligned} \right\}$$

性质 7.5

如果 $(X_i, Y_i) i.i.d \sim P_{XY}(x, y)$, 那么 $\forall \varepsilon > 0$

- $P((x^n, y^n) \in A_\varepsilon^{(n)}(X, Y)) \xrightarrow{n \rightarrow \infty} 1$ (类似性质 3.3) (7.7)
- $p(\text{集合中元素}) \leq 2^{-n(H(X)-\varepsilon)}$ (类似性质 3.4)
- $|A_\varepsilon^{(n)}(X, Y)| \leq 2^{n(H(X, Y)+\varepsilon)}$ (类似性质 3.5)

性质 7.6

假如 $\tilde{X}_i$ 和 $\tilde{Y}_i$ 相互独立, 且 $\tilde{X}_i \sim X$, $\tilde{Y}_i \sim Y$, 即:

$$\tilde{X}_i \text{ i.i.d. } \sim P_X(x) = \sum_Y P_{XY}(x, y)$$

$$\tilde{Y}_i \text{ i.i.d. } \sim P_Y(y) = \sum_X P_{XY}(x, y)$$

如果 $\tilde{x}^n$ 来自 $\tilde{X}^n$, $\tilde{y}^n$ 来自 $\tilde{Y}^n$, 则 $(\tilde{x}^n, \tilde{y}^n)$ 落在典型集 $A_\epsilon^{(n)}(X, Y)$ 中的概率为:

$$p((\tilde{x}^n, \tilde{y}^n) \in A_\epsilon^{(n)}(X, Y)) \leq 2^{-n(I(X;Y)-3\epsilon)}$$

证明.

$$\begin{aligned} p((\tilde{x}^n, \tilde{y}^n) \in A_\epsilon^{(n)}(X, Y)) &= \sum_{(x^n, y^n) \in A_\epsilon^{(n)}(X, Y)} p(x^n)p(y^n) \\ &\leq |A_\epsilon^{(n)}(X, Y)| 2^{-n(H(X)-\epsilon)} 2^{-n(H(Y)-\epsilon)} \\ &\leq 2^{(n(H(X,Y)+\epsilon))} 2^{-n(H(X)-\epsilon)} 2^{-n(H(Y)-\epsilon)} \\ &= 2^{-n(I(X;Y)-3\epsilon)} \end{aligned}$$

□

正向命题的证明

$n \rightarrow \infty$ 时, 要想存在编码方案 C_n^* , 使得

$$P(\hat{U} \neq U | C_n^*) \xrightarrow{n \rightarrow \infty} 0$$

只需

$$\mathbb{E}_{C_n \sim C} P(\hat{U} \neq U | C_n) \xrightarrow{n \rightarrow \infty} 0$$

(这是因为误差最小编码方案 C_n^* 满足 $P(\hat{U} \neq U | C_n^*) \leq \mathbb{E}_{C_n \sim C} P(\hat{U} \neq U | C_n)$)

而

$$\begin{aligned} \mathbb{E}_{C_n \sim C} P(\hat{U} \neq U | C_n) &= P(\hat{U} \neq U) \\ &= \sum_{u \in \mathcal{U}} P(U = u) P(\hat{u} \neq u | U = u) \end{aligned}$$

所以只需

$$\forall u \in \mathcal{U}, P(\hat{u} \neq u | U = u) \xrightarrow{n \rightarrow \infty} 0 \quad (7.8)$$

如下设计编码方案的分布 C :

1. 任取 P_X , 然后取 $R < I(X; Y)$.
2. **编码** 从 $A_\epsilon^{(n)}(X)$ 的约 $2^{nH(X)}$ 个典型序列中**独立地**随机选取 M 个作为码字集 $\{x^n(i)\}_{i=1}^M$ (因为 $M = 2^{nR} \leq 2^{nI(X;Y)} \leq 2^{nH(X)}$, 这是可行的).
3. **译码** 发送状态 $U = u$, 收到 y^n , 若存在唯一 s 使 $(x^n(s), y^n) \in A_\epsilon^{(n)}(X, Y)$, 则译码 $\hat{u} = s$.

$\hat{u} = u | U = u$ 的充要条件是

$$(x^n(u), y^n) \in A_\epsilon^{(n)}(X, Y) \text{ 且 } \forall k \neq u, (x^n(k), y^n) \notin A_\epsilon^{(n)}(X, Y)$$

所以 $\hat{u} \neq u \mid U = u$ 的充要条件是

$$(x^n(u), y^n) \notin A_\varepsilon^{(n)}(X, Y) \text{ 或 } \exists (x^n(k), y^n) \in A_\varepsilon^n(X, Y)$$

所以

$$\begin{aligned} P(\hat{u} \neq u \mid U = u) &= P((x^n(u), y^n) \notin A_\varepsilon^{(n)}(X, Y) \text{ 或 } \exists (x^n(k), y^n) \in A_\varepsilon^n(X, Y) \mid U = u) \\ &\leq \underbrace{P((x^n(u), y^n) \notin A_\varepsilon^{(n)}(X, Y) \mid U = u)}_{\text{根据式 (7.7) 此项 } \xrightarrow{n \rightarrow \infty} 0} \\ &\quad + \sum_{k \neq u} P(x^n(k), y^n \in A_\varepsilon^n(X, Y) \mid U = u) \end{aligned}$$

下面考虑第二项, 注意到 $x^n(k) \sim P_X, y^n \sim \sum_X P_X P_{Y|X} = P_Y$, 而且 $k \neq u$ 时, $x^n(k) \perp x^n(u)$, 从而 $x^n(k) \perp y^n$, 由性质 7.6 得

$$\begin{aligned} \sum_{k \neq u} P(x^n(k), y^n \in A_\varepsilon^n(X, Y) \mid U = u) &\leq (M-1)2^{-n(I(X;Y)-3\varepsilon)} \\ &\leq M2^{-n(I(X;Y)-3\varepsilon)} \\ &\leq 2^{nR}2^{-n(I(X;Y)-3\varepsilon)} \\ &\leq 2^{-n(I(X;Y)-R-3\varepsilon)} \end{aligned}$$

取 $R < I(X;Y)$ 时 取充分小的 $\varepsilon, 2^{-n(I(X;Y)-R-3\varepsilon)} \xrightarrow{n \rightarrow \infty} 0$, 所以

$$\sum_{k \neq u} P(x^n(k), y^n \in A_\varepsilon^n(X, Y) \mid U = u) \xrightarrow{n \rightarrow \infty} 0$$

进而

$$P(\hat{u} \neq u \mid U = u) \xrightarrow{n \rightarrow \infty} 0$$

也就在 $R < I(X;Y)$ 的条件下, 得到了式 (7.8).

在设计编码方案分布 C 时, 取 $P_X = \arg\max_{P_X} I(X;Y)$, 那么式 (7.8) 的条件 ($R < I(X;Y)$) 的条件即变为 $R < P_X = \max_{P_X} I(X;Y)$. 从而正向命题得证.

注解 7.7

如果状态 U 均匀分布, 那么最优编码方案 C_n^* 的单个状态最大错误率能逼近 0:

$$\max_u P\hat{U} \neq U \mid U = u, C_n^* \xrightarrow{n \rightarrow \infty} 0$$

性质 7.8 (无记忆信道的互信息不等式)

$$I(X^n; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i)$$

证明.

$$I(X^n; Y^n) = H(Y^n) - H(Y^n \mid X^n)$$

□

$$\begin{aligned}
&= H(Y^n) - \sum_{i=1}^n H(Y_i | X_i) \\
&\leq \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i | X_i) \\
&= \sum_{i=1}^n I(X_i; Y_i)
\end{aligned}$$

□

反向命题的证明

结合性质 7.8 和 定理 5.2 可得:

$$I(U; Y^n) \leq I(X^n; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq nC^I$$

当 U 均匀分布时, $P(\hat{U} \neq U) = \frac{1}{M} \sum_{i=1}^M P(\hat{U} \neq U | U = i)$ 代表平均错误率.

在 $U \rightarrow Y^n \rightarrow \hat{U}$ 中, 由定理 5.7

$$\begin{aligned}
P(\hat{U} \neq U) &\geq 1 - \frac{I(U; Y^n) + 1}{H(U)} \\
&= 1 - \frac{I(U; Y^n) + 1}{\log M} \\
&\geq 1 - \frac{nC^I}{\log M} - \frac{1}{\log M} \\
&= 1 - \frac{C^I}{R} - \frac{1}{nR}
\end{aligned}$$

$R > C^I, n \rightarrow \infty$ 时, $P(\hat{U} \neq U) > 0$


□

注解 7.9 (反馈信道)

因为反馈信道仍然满足

$$I(U; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq nC^I$$

所以反馈信道依然适用反向命题的证明, 这说明引入反馈不能提高信道容量. 任何反馈信道都可以的信道容量都可以被不带反馈的信道达到.



离散无记忆信道的马尔可夫性

$$Y^{i-1}, U \longrightarrow X_i \longrightarrow Y_i$$

离散无记忆反馈信道仍然满足:

$$I(U; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq nC^I$$

根据Fano 不等式:

$$\text{如果 } R > C^I, \text{ 则 } P(\hat{U} \neq U) > 0$$

结论: 使用反馈, 离散无记忆信道的最高传输率仍然为 C^I

$$I(U; Y^n) = H(Y^n) - H(Y^n|U)$$

$$= \sum_{i=1}^n H(Y_i|Y^{i-1}) - \sum_{i=1}^n H(Y_i|Y^{i-1}, U)$$

$$\leq \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i|Y^{i-1}, U)$$

$$\leq \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i|Y^{i-1}, U, X_i)$$

$$= \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i|X_i) = \sum_{i=1}^n I(X_i; Y_i) \leq nC^I$$

$$p(Y_i|Y^{i-1}, U, X_i) = p(Y_i|X_i)$$

八、连续的情形

概念: 微分熵 (不保持非负性) 等

性质 8.1 (微分熵的变量替换)

$$h(AX + c) = h(X) + \log|\det(A)|$$

注解 8.2

用精度 Δ 量化连续分布 $p_k = \int_{k\Delta}^{(k+1)\Delta} f(x)dx = f(x_k)\Delta, \exists x_k$, 那么离散分布 $X^\Delta \sim p_k$ 的熵

$$H(X^\Delta) \approx h(X) + \log \frac{1}{\Delta}$$

如果 $\Delta = 2^{-n}$, 则 $H(X^\Delta) \approx h(X) + n$ 为将 X 量化成 n bit 精度, 需要的平均 bit 数

8.1 高斯分布

💡 提示

$$\text{tr}(\mathbb{E}_p[X]) = \mathbb{E}_p[\text{tr}(X)]$$

$$\text{tr}(ABC) = \text{tr}(CAB) = \text{tr}(BCA)$$

性质 8.3 (微分熵)

$X^n = (X_1, X_2, \dots, X_n) \sim \mathcal{N}(\mu, \Sigma)$ 那么

$$h(X^n) = h(X_1, X_2, \dots, X_n) = \frac{n}{2} \log(2\pi e) + \frac{1}{2} \log|\Sigma|$$

性质 8.4 (高斯分布是最大微分熵分布)

对任意 n 维期望为 μ 且协方差为 Σ 的分布 X^n , 其熵:

$$h(X^n) \leq \frac{n}{2} \log(2\pi e) + \frac{1}{2} \log|\Sigma|$$

证明. 记 X^n 的分布为 f . 记 n 维期望为 μ , 方差为 Σ 的高斯分布为 g .

$$\begin{aligned} h(X^n) &= D_{\text{KL}}(f \| g) + \text{CE}(f, g) \\ &\leq \text{CE}(f, g) \\ &= \mathbb{E}_f[-\log g(x)] \\ &= \frac{1}{2} \mathbb{E}_f[n \log(2\pi) + \log(|\Sigma|) + \log e(x - \mu)^T \Sigma^{-1} (x - \mu)] \\ &= \frac{1}{2} (n \log(2\pi) + \log(|\Sigma|)) + \log e \mathbb{E}_f[\text{tr}((x - \mu)^T \Sigma^{-1} (x - \mu))] \end{aligned}$$

$$= \frac{n}{2} \log(2\pi e) + \frac{1}{2} \log |\Sigma|$$

最后一步是因为

$$\begin{aligned} \mathbb{E}_f[\text{tr}((x - \mu)^T \Sigma^{-1} (x - \mu))] &= \mathbb{E}_f[\text{tr}(\Sigma^{-1} (x - \mu)(x - \mu)^T)] \\ &= \text{tr}(\mathbb{E}_f[\Sigma^{-1} (x - \mu)(x - \mu)^T]) \\ &= \text{tr}(\Sigma^{-1} \mathbb{E}_f[(x - \mu)(x - \mu)^T]) \\ &= \text{tr}(\Sigma^{-1} \Sigma) \\ &= n \end{aligned}$$

注解 8.5

从该证明中可见, 对于高斯分布 $g(x)$, 任意同期望, 同方差的分布 $f(x)$

$$\text{CE}(g, f) = h(g)$$

□

性质 8.6 (互信息)

$$I(X^m; Y^n) = h(X^m) + h(Y^n) - h(X^m, Y^n) = \frac{1}{2} \log \frac{|\Sigma_{X^m}| |\Sigma_{Y^n}|}{|\Sigma_{joint}|}$$

注解 8.7 (高斯分布的互信息衡量线性相关性)

$I(X_1; X_2) = 0$ 当且仅当 $\rho = 0$

$$I(X_1; X_2) = \frac{1}{2} \log \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 \sigma_2^2 (1 - \rho^2)} = -\frac{1}{2} \log(1 - \rho^2)$$

性质 8.8 (KL 散度)

$p(x) = \mathcal{N}(\mu_1, \Sigma_1)$, $q(x) = \mathcal{N}(\mu_2, \Sigma_2)$ 那么

$$\begin{aligned} D_{KL}^{(\log_2^*)}(p||q) &= \frac{1}{\ln 2} D_{KL}^{(\ln^*)}(p||q) \\ D_{KL}^{(\ln)}(p||q) &= \int p(x) \ln \frac{p(x)}{q(x)} dx \\ &= \frac{1}{2} \ln \frac{|\Sigma_2|}{|\Sigma_1|} - \frac{n}{2} + \frac{1}{2} \text{tr}(\Sigma_2^{-1} \Sigma_1) + \frac{1}{2} (\mu_2 - \mu_1)^T \Sigma_2^{-1} (\mu_2 - \mu_1) \end{aligned}$$

8.2 高斯信道

定义 8.9 (高斯信道)

$$Y_i = X_i + W_i$$

$$W_i \sim \mathcal{N}(0, \sigma^2)$$

X_i 幅度越大噪声影响越小, 但幅度不能无限大, 表现为功率限制:

$$\mathbb{E}[X_i^2] \leq P$$

性质 8.10 (高斯信道的容量)

$$\begin{aligned} I(X; Y) &= h(Y) - h(Y|X) \\ &= h(Y) - h(X + W | X) \\ &\leq h(\mathcal{N}(0, \text{Var}(X) + \sigma^2)) - h(W|X) \\ &= h(\mathcal{N}(0, \text{Var}(X) + \sigma^2)) - h(\mathcal{N}(0, \sigma^2)) \\ &= \frac{1}{2} \log \left(1 + \frac{P}{\sigma^2} \right) \end{aligned}$$

当 X 取 $\mathcal{N}(0, P)$ 的时候取得等号.

注解 8.11 (高斯信道的容量的几何解释)

◆ 几何解释


$$\mathbb{E} \left[\sum_{i=1}^n Y_i^2 \right] = \sum_{i=1}^n \mathbb{E}[Y_i^2] \approx \sum_{i=1}^n (\mathbb{E}[X_i^2] + \mathbb{E}[W_i^2]) \leq \sum_{i=1}^n (P + \sigma^2) = n(P + \sigma^2)$$

$$\sum_{i=1}^n Y_i^2 \leq n(P + \sigma^2) \Leftrightarrow \sqrt{\sum_{i=1}^n Y_i^2} \leq \sqrt{n(P + \sigma^2)}$$

输出空间半径: $\sqrt{n(P + \sigma^2)}$

噪声球半径: $\sqrt{n}\sigma$

输入空间半径: $\sqrt{nP}$



$$\#spheres = \frac{\text{output volume}}{\text{sphere volume}} = \frac{(\sqrt{n(P + \sigma^2)})^n}{(\sqrt{n}\sigma)^n} = \left(1 + \frac{P}{\sigma^2} \right)^{\frac{n}{2}}$$

$$R = \frac{\log_2(\#spheres)}{n} = \frac{1}{n} \log_2 \left(1 + \frac{P}{\sigma^2} \right)^{\frac{n}{2}} = \frac{1}{2} \log \left(1 + \frac{P}{\sigma^2} \right)$$

定义 8.12 (并行高斯信道)

单个功率限制为 P 高斯信道的容量为 $C^I = \frac{1}{2} \log(1 + \frac{P}{\sigma^2})$. 当每个信道可以并行传输, 且各自的噪声 W_i 具有自己的方差 N_i^2 时, 形成并行高斯信道:

$$Y_i = X_i + W_i, \quad W_i \sim \mathcal{N}(0, N_i), \quad i = 1, 2, \dots, n$$

要求解的问题是: 如何分配功率, 使总信道容量最大, 即


$$\begin{aligned} \max_{\{P_i\}} & \frac{1}{2} \log \left(1 + \frac{P}{N_i} \right) \\ \text{s.t.} & \sum_i P_i = P \\ & P_i \geq 0 \end{aligned}$$

注解 8.13 (水填充)

利用 KKT 条件求解上述问题, 可以得到如下解

$$\begin{aligned} P_i^* &= (\mu - N_i)^+ = \max(\mu - N_i, 0) \\ \sum_{i=1}^n (\mu - N_i)^+ &= P \end{aligned}$$

形象地理解为“水填充”问题: 用 P 体积的水来填充位置 i 处高度为 N_i 的水池, 填充完之后各个位置的水深即为对应信道分配的功率 P_i . 这个问题的求解, 可以用二分答案法.



九、Hamming 码

概念: 零空间编码、Galois-field 算数、GF(2)

定义 9.1 (零空间编码)

对于变换 H , 零空间 $\text{Null}(H) = \{x \mid Hx = 0\}$, 取 $\text{Null}(H)$ 为数据流形.

定义 9.2 (GF(2)域)

GF(2)域采用数域 $\{0, 1\}$, 用异或替代加法运算.

注解 9.3

GF(2) $^{m \times n}$ 上的矩阵, 也满足秩-零度定理

定义 9.4 (Hamming 码)

在零空间编码中, 取变换 H 为 GF(2)域上的矩阵, 第 k 列为二进制数 k 的位向量. H 有 m 行, $n = 2^m - 1$ 列. 这样的零空间编码, 称为 **Hamming 码**. 矩阵 H 也称 Hamming 矩阵.

性质 9.5 (Hamming 矩阵满秩)

H 第 2^t ($t = 0, 1, 2, \dots, m-1$) 列组合成的子矩阵行列式非零, 所以 H 满秩, $\text{Rank}(H) = m$, 零空间维度为 $n - m$, 这也是可用于编码数据的位数.

性质 9.6 (Hamming 纠错)

传输数据(二进制序列) x^n 只错第 k 位时, $H(x^n + e_k) = He_k = H$ 第 k 列 H_k . 只错一位时, 可以纠错.

错两位时, 可检测.

错三位以上, 无法检测.

注解 9.7 (求解 H 的零空间)

H 第 2^t ($t = 0, 1, 2, \dots, m-1$) 列天然可以当作主元列, 此时主元的结果是所该主元所涉及的其他位的异或和, 即 1 出现的奇偶性.

这给出了用“奇偶校验”法求 H 的零空间的方法: 对所有非主元任意赋值, 然后用主元存奇偶校验的结果.

注解 9.7 也给出了如何在零空间存储数据: 在非主元存数据, 用主元存做奇偶校验位. 这也直观地解释了可用于编码数据的位数为何为 $n - m$.

在收到数据 x^n 后, Hx^n 就给出了每一个校验位的奇偶校验结果. 由此, 实际解码过程中, 可不用计算矩阵乘法, 而用分组奇偶校验替代.

性质 9.8 (Hamming 矩阵零空间的性质)

- 除了全零元之外, 其他码字非零元个数均不小于 3

证明: H 的各列向量不相同

- 不同码字之间汉明距离均不小于 3

证明:


$$D_H(x^n, y^n) = \sum_{k=1}^n x_k \oplus y_k = |x^n + y^n| = |z^n| \geq 3$$

注解 9.9

第二点性质, 也为性质 9.6 提供了直观解释:

每个码字之间的距离不小于 3, 从合法码字出发, 当偏差 1 步时可以归类的最近的码字上, 当偏差 2 步时可以检测错误, 当偏差 3 步时有可能偏移到其他码字上, 无法检测是否出错.

十、率失真



概念: 压缩率(Rate)、失真度、可达与不可达

定义 10.1 (率失真函数)

率失真函数 $R(D)$ 表示给定失真度限制 D 时, 最小可达压缩率 R , 即

$$\min R$$

$$s.t. \mathbb{E}[d(V^N, \hat{V}^N)] = \mathbb{E}[d(V, \hat{V})] \leq D$$

率失真定理说明

$$R(D) = R^I(D) = \min_{p(\hat{V}|V)} I(V, \hat{V})$$

性质 10.2 (凸性)

$R^I(D)$ 是凸函数, 即

$$\forall D_1, D_2, 0 \leq \lambda \leq 1: R^I(\lambda D_1 + (1 - \lambda) D_2) \leq \lambda R^I(D_1) + (1 - \lambda) R^I(D_2)$$

性质 10.3 (零失真)

$$R(0) = H(V)$$

性质 10.4 (零码率)

存在 D_{max} , 使得 $R(D_{max}) = 0$. 且当 $D \geq D_{max}$ 时, $R(D) = 0$

$$D_{max} = \min_{p(\hat{V})} \sum_{p(\hat{V})} \sum_{p(V)} p(\hat{V}) p(V) d(V, \hat{V})$$

性质 10.5 (单调递减)

$R(D) = R^I(D)$ 是单调递减函数

命题 10.6 (高斯信源的率失真)

高斯信源 $V \sim \mathcal{N}(0, \sigma^2)$, 取失真函数 $d(v, \hat{v}) = (v - \hat{v})^2$, 那么高斯信源的率失真函数为

$$R^I(D) = \begin{cases} \frac{1}{2} \log \frac{\sigma^2}{D}, & 0 \leq D \leq \sigma^2 \\ 0, & D > \sigma^2 \end{cases}$$

证明.

$$\begin{aligned}
 I(V; \hat{V}) &= H(V) - H(V|\hat{V}) \\
 &= H(V) - H(V - \hat{V} | \hat{V}) \\
 &\geq H(V) - H(V - \hat{V}) \quad (\text{当且仅当 } V - \hat{V} \perp \hat{V} \text{ 时取等}) \\
 &\geq H(V) - H(\mathcal{N}(0, D)) \quad (\text{当且仅当 } V - \hat{V} \sim \mathcal{N}(0, D) \text{ 时取等}) \\
 &= \frac{1}{2} \log \frac{\sigma^2}{D}
 \end{aligned}$$


$0 \leq D \leq \sigma^2$ 时, 令 $G \sim \mathcal{N}(0, D)$ $V = \hat{V} + G$. $\hat{V}$ 与 G 独立. 可以满足取等条件.
 $D > \sigma^2$ 时, 取 $\hat{V} = 0$ 可满足 $\mathbb{E}[(\hat{V} - V)^2] \leq D$, 同时 $I(V; \hat{V}) = 0$.

□

注解 10.7 (几何解释)

高斯信源 $V \sim \mathcal{N}(0, \sigma^2)$

◆ 失真函数 $d(v, \hat{v}) = (v - \hat{v})^2$



$$R(D) = \begin{cases} \frac{1}{2} \log \frac{\sigma^2}{D}, & 0 \leq D \leq \sigma^2 \\ 0, & D > \sigma^2 \end{cases}$$

$$V \sim \mathcal{N}(0, \sigma^2) \implies \mathbb{E} \left[\sum_{i=1}^n V_i^2 \right] \approx n\sigma^2$$

$$\mathbb{E}[(V - \hat{V})^2] \leq D \implies \mathbb{E} \left[\sum_{i=1}^n (V_i - \hat{V}_i)^2 \right] \approx nD$$

$$M \geq \frac{\text{volume of data sphere}}{\text{volume of noisy ball}} = \frac{(\sqrt{n\sigma^2})^n}{(\sqrt{nD})^n} = \left(\frac{\sigma^2}{D} \right)^{\frac{n}{2}}$$


$$R = \frac{\log_2 M}{n} \geq \frac{1}{2} \log \frac{\sigma^2}{D}$$

注解 10.8 (信源信道可分离)

信源信道联合编码, 不能取得分离编码达不到的速率.


证明.

联合编码



分离编码

如果 $NR^I(D) \leq nC^I$, 则存在下面 “信源-信道分离编码方案”



$$NR^I(D) \leq nC^I \Leftrightarrow \exists M, NR^I(D) \leq \log M \leq nC^I \Leftrightarrow \text{存在速率为 } \frac{N}{n} \text{ 的分离编码方案}$$

所以

$$\text{存在速率为 } \frac{N}{n} \text{ 的联合编码方案} \Rightarrow NR^I(D) \leq nC^I \Leftrightarrow \text{存在速率为 } \frac{N}{n} \text{ 的分离编码方案}$$

也就是说, 任意联合编码方案, 都存在能达到相等速率的分离编码方案. □